Méthodes Quantitatives pour les sciences humaines et sociales

Séance 2 et 3 : Décrire une variable

Ahmed BAHIAOUI

Sciences Po

janvier-avril 2025

SciencesPo

Sommaire

1. Avant-propos
2. Distribution
3. Tendance centrale
4. Dispersion

SciencesPo

Sommaire

1. Avant-propos
2. Distribution
3. Tendance centrale
4. Dispersion

SciencesPo

Format du cours

- Hors première séance, cours très pratique
- Le contrôle continu (et l'examen final) porte tout autant sur les notions théoriques que sur les informations pratiques
- Aucune installation spécifique préalable : Tout se fera sur Excel
- Utilisez les ordinateurs de la salle informatique, pensez à un moyen pour garder vos fichiers
- Ou révisez plus tard en essayant de répliquer les exercices chez vous avec votre ordinateur personnel

SciencesPo

Rappel : Premier contrôle continu la semaine prochaine

Petite explication de l'exercice

Sommaire

1. Avant-propos
2. Distribution
3. Tendance centrale
4. Dispersion

SciencesPo

Prenons un cas de figure simple

- Vous disposez pour une certaine classe, des notes obtenus au BAC par les étudiants
- Vous pouvez récupérer ces données sur Drive ici.

SciencesPo

Prenons un cas de figure simple

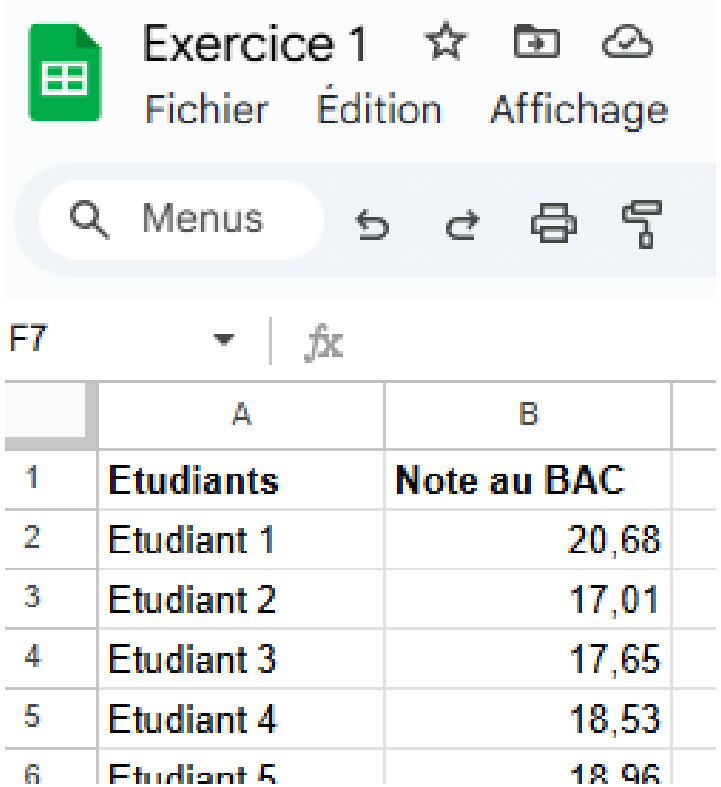

	A	B
1	**Etudiants**	**Note au BAC**
2	Etudiant 1	20,68
3	Etudiant 2	17,01
4	Etudiant 3	17,65
5	Etudiant 4	18,53
6	Etudiant 5	18,96

Figure: Données de notes d'étudiants au BAC

Quelques éléments de jargon

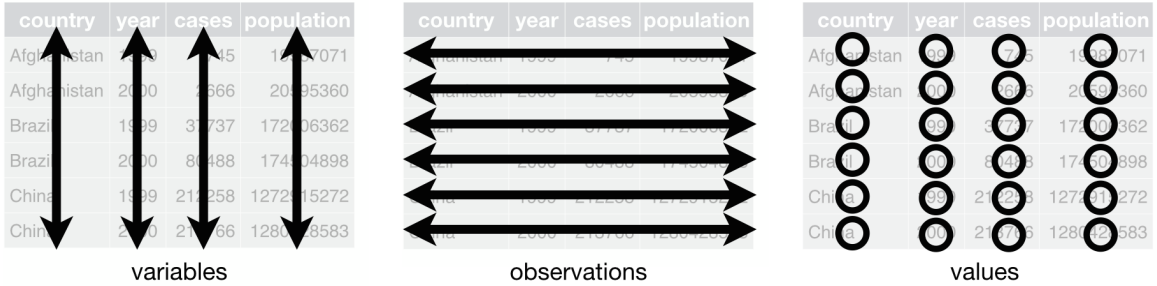

Le jargon des bases de données

Les colonnes sont des **variables**.

Les lignes sont des **observations**.

Les cellules sont des **valeurs**.

La première variable est habituellement une variable qui permet d'identifier chaque observation. Elle est appelée **clé**.

SciencesPo

On veut quand même voir toute les notes...

	A	B
	Etudiants	Note au BAC
	Etudiant 1	20,68
	Etudiant 2	17,01
	Etudiant 3	17,65
	Etudiant 4	18,53
	Etudiant 5	18,96
	Etudiant 6	17,18
	Etudiant 7	17,78
	Etudiant 8	16,91
	Etudiant 9	20,73
	Etudiant 10	19,32
	Etudiant 11	18,81
	Etudiant 12	19,55
	Etudiant 13	17,68
	Etudiant 14	17,73
	Etudiant 15	16,36
	Etudiant 16	19,04
	Etudiant 17	17,75
	Etudiant 18	18,21
	Etudiant 19	18,24
	Etudiant 20	17,43
	Etudiant 21	18,05
	Etudiant 22	18,35
	Etudiant 23	16,58
	Etudiant 24	17,69
	Etudiant 25	16,19
	Etudiant 26	15,57
	Etudiant 27	17,41
	Etudiant 28	18,36
	Etudiant 29	17,29

Figure: Données de notes d'étudiants au BAC

Comment mieux présenter ces données?

- Une façon de mieux présenter ces chiffres serait de s'appuyer sur une représentation graphique

Créer un graphique à partir des données

Pour créer un graphique, il faut commencer par **sélectionner** les données qu'on souhaite représenter, puis sous le menu **Insertion**, choisir **Graphique**. Plusieurs types de graphiques sont possibles: Nuage de points, colonnes, courbes, secteurs, etc.

Représentation graphique des notes

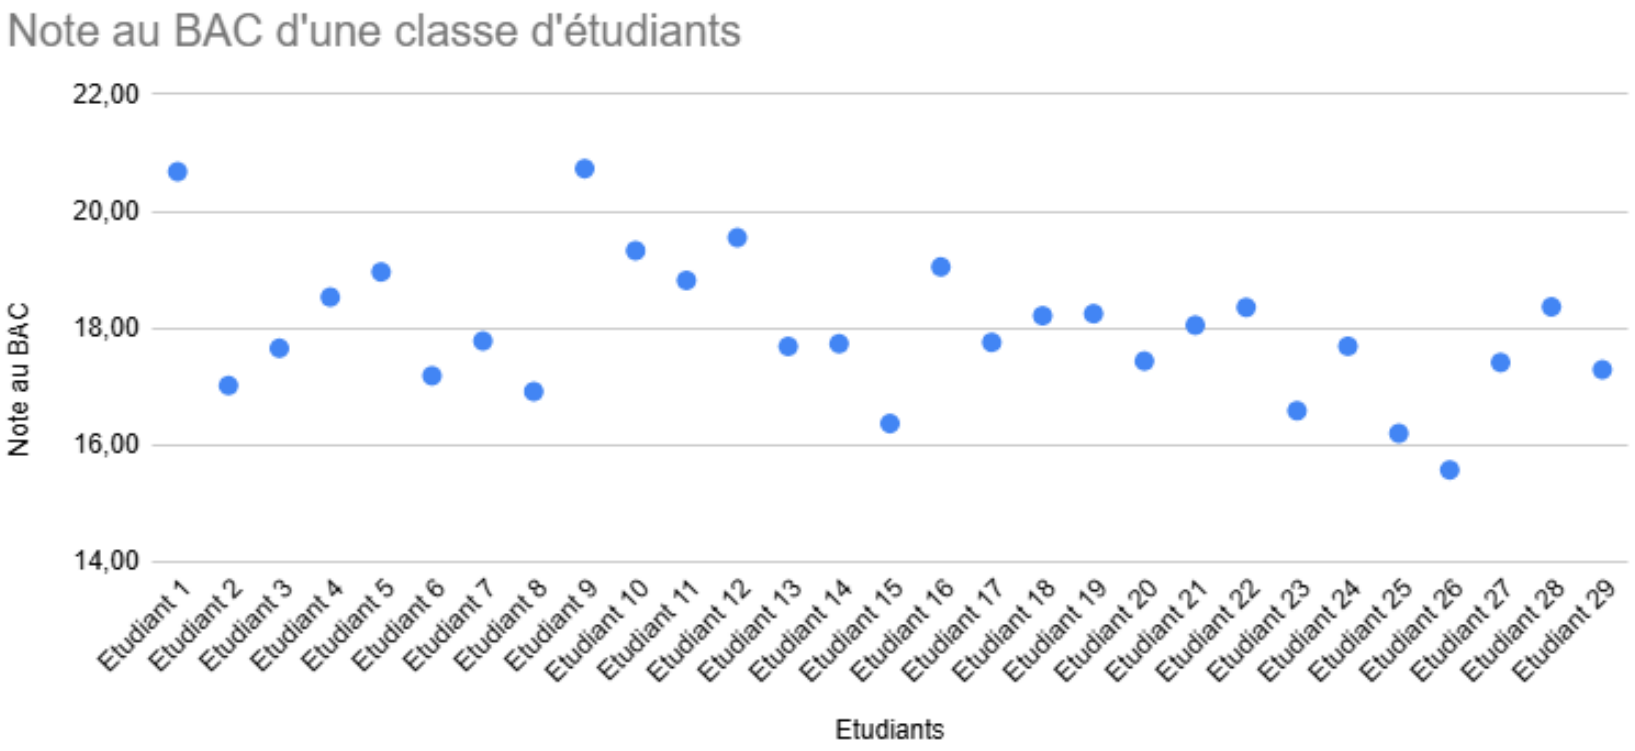

Figure: Représentation des notes comme nuage de points

Représentation graphique des notes

- Cette représentation n'est pas satisfaisante
- Elle ne permet pas de tirer des conclusions sur ces notes

Représentation graphique des notes

- Cette représentation n'est pas satisfaisante
- Elle ne permet pas de tirer des conclusions sur ces notes
- Une façon d'améliorer ceci est de **grouper** les élèves dont les notes sont similaires.

Grouper les données

La fonction de **tableaux croisés dynamiques** permet de grouper les données selon le critère voulu. Toujours en sélectionnant les données et en choisissant l'option tableaux croisés dynamiques sous le menu insertion. Un clic-droit permet de changer les règles de groupement des valeurs

SciencesPo

Distribution des notes

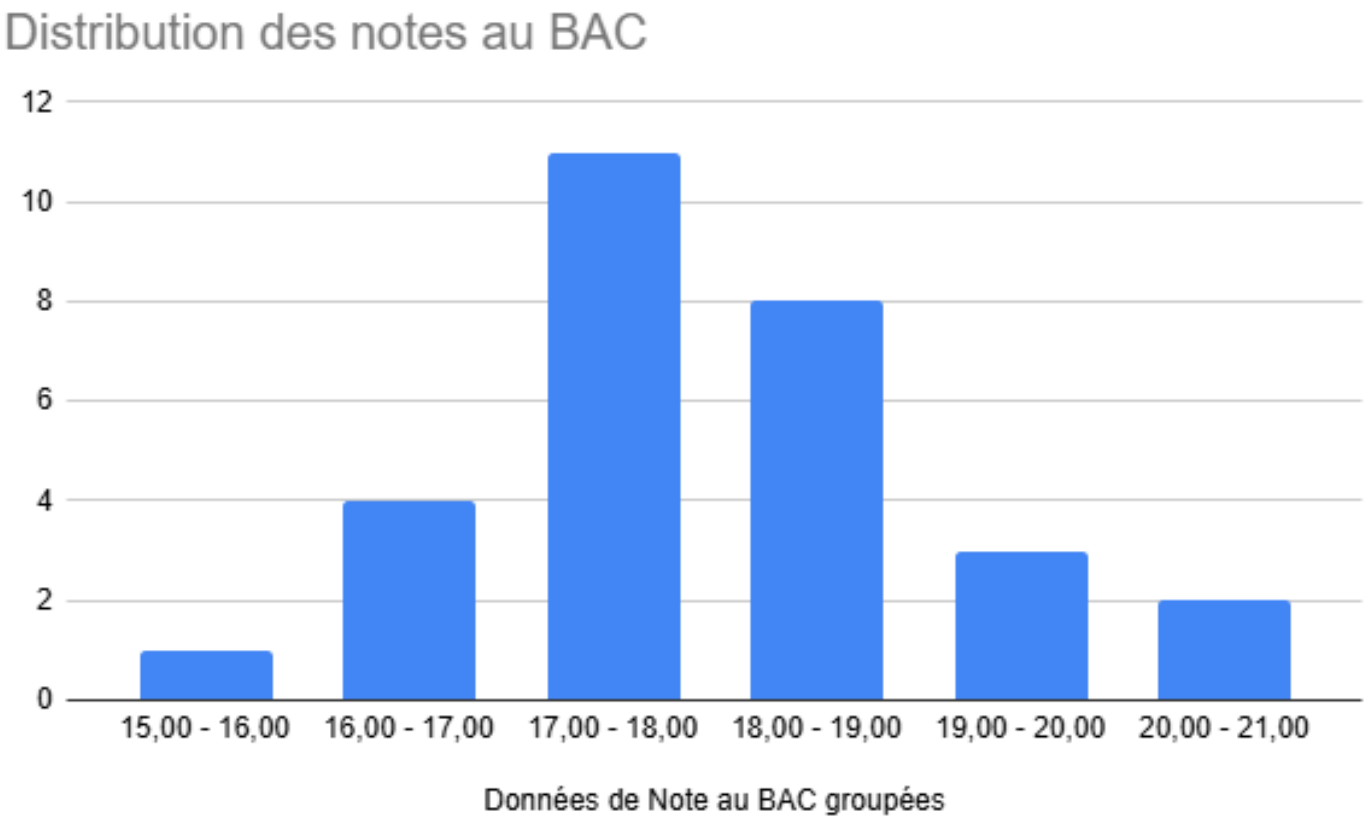

Figure: Distribution des notes en nombre d'élève

SciencesPo

Distribution des notes

- Permet déjà de savoir combien d'élèves ont telle ou telle note.
- Ne permet pas de savoir combien d'élèves ont une note supérieure ou inférieure à un niveau
- Comment savoir par exemple combien d'élèves ont une note inférieure à 19 par exemple ?

Distribution des notes

- Permet déjà de savoir combien d'élèves ont telle ou telle note.
- Ne permet pas de savoir combien d'élèves ont une note supérieure ou inférieure à un niveau
- Comment savoir par exemple combien d'élèves ont une note inférieure à 19 par exemple ?
  - Il faut produire la distribution **cumulative**

SciencesPo

Distribution cumulative des notes

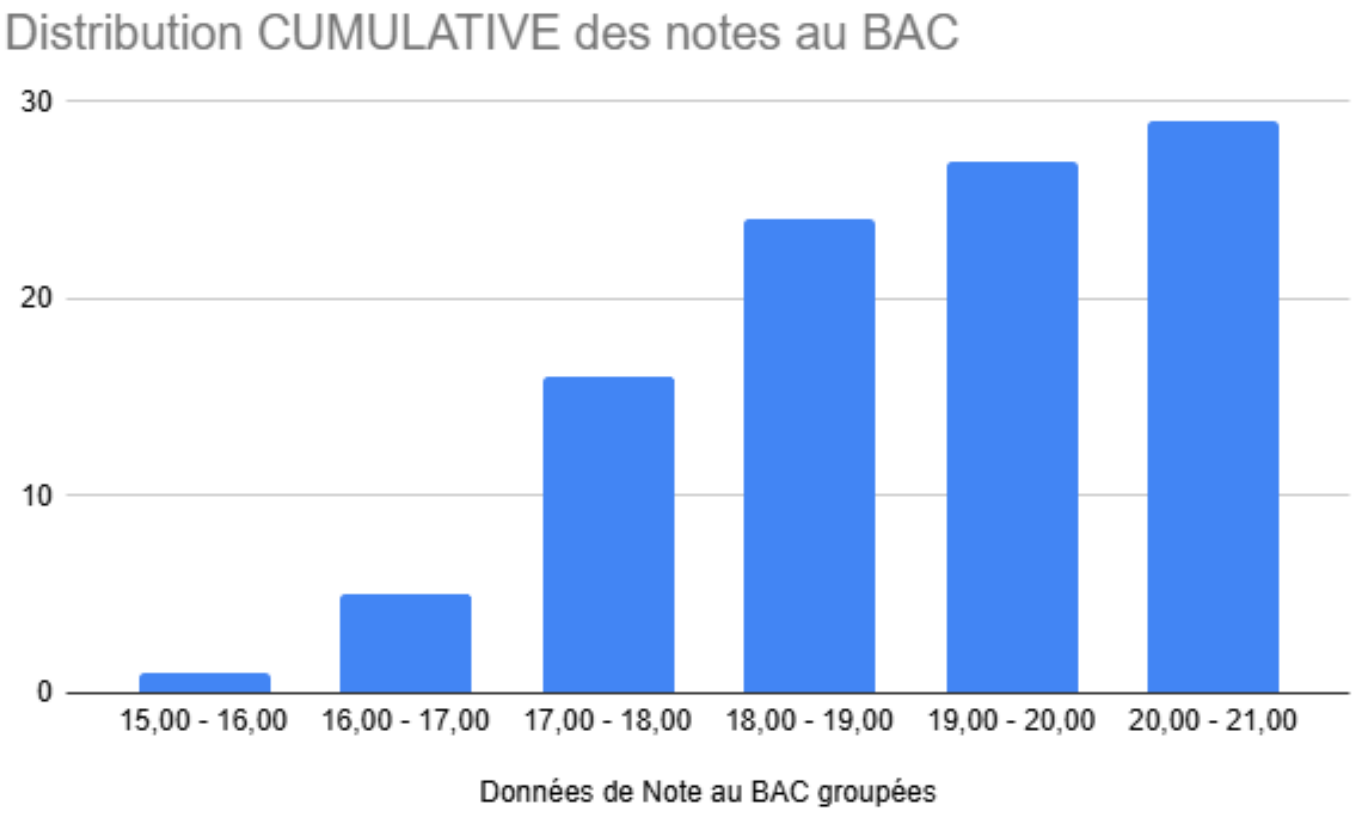

Figure: Distribution cumulative des notes en nombre d'élèves

SciencesPo

A quoi correspond la distribution cumulative?

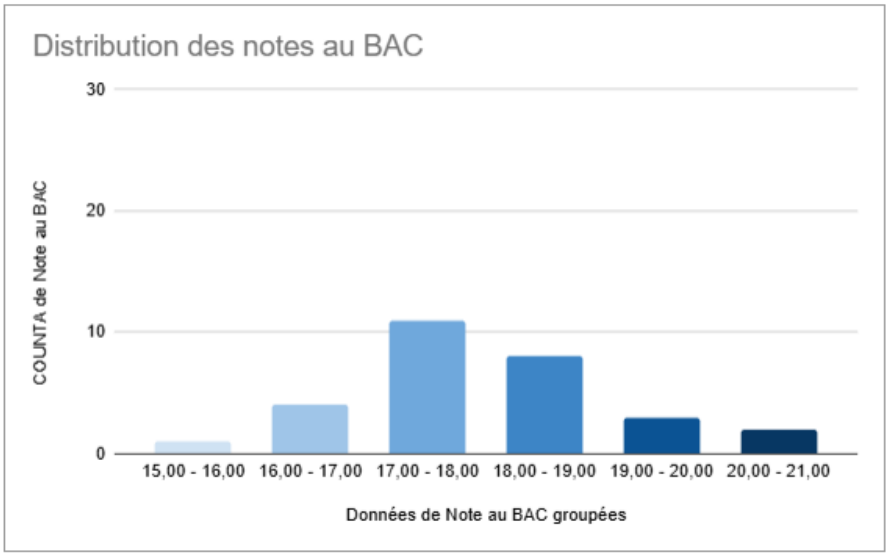

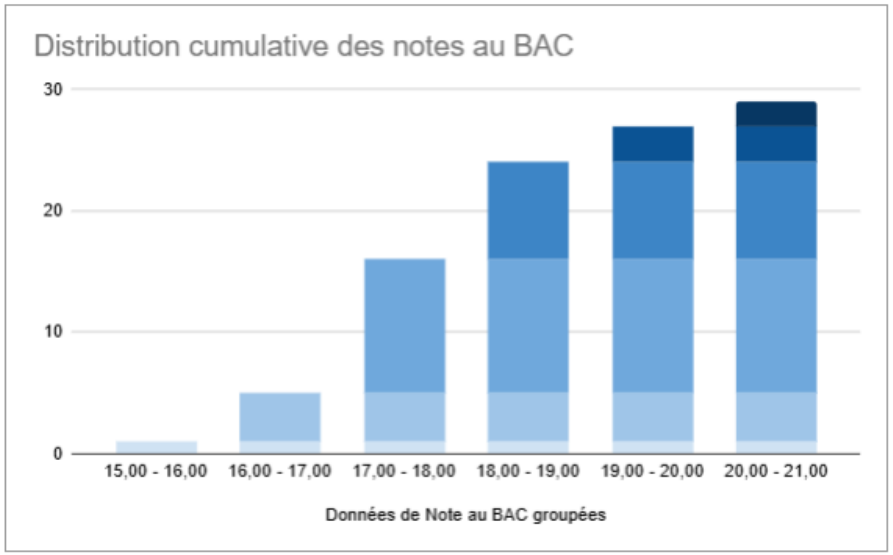

Figure: Comment imaginer la distribution cumulative ?

La distribution cumulative en pratique

Créer un graphique de distribution cumulative

Pour produire la distribution cumulative, il faut créer un nouvelle série d'effectifs cumulés. Pour ceci, on peut s'appuyer sur la fonction SOMME(DEBUT : FIN). Pour répliquer la formule, il suffit de "tirer" sur le coin bas-droit de la case. N'oubliez pas qu'Excel et Sheets permet de fixer une case en utilisant des signe de Dollar :

- L'écriture B2, changera horizontalement et verticalement avec le remplissage automatique
- L'écriture $B2, changera verticalement mais restera sur la colonne B
- L'écriture B$2, changera horizontalement mais restera sur la ligne 2
- L'écriture B2, ne changera pas avec le remplissage automatique

SciencesPo

Exercice 1

1. Répliquer le graphique de nuage de points des notes (brutes)
2. Créer un tableau dynamique croisé avec la répartition des notes
3. Répliquer le graphique de distribution des notes
4. Répliquer le graphique de la distribution cumulative des points
5. Changer la représentation en **pourcentages** plutôt qu'en **effectifs**

SciencesPo

Sommaire

1. Avant-propos
2. Distribution
3. Tendance centrale
4. Dispersion

SciencesPo

Et si l'on cherchait à synthétiser davantage l'information apportée par ces données en un chiffre ?

Le centre de la distribution

- Cette valeur **centrale** à la distribution s'appelle la moyenne
- Elle est définie comme la valeur qui se rapproche le plus de l'ensemble des points

Le centre de la distribution

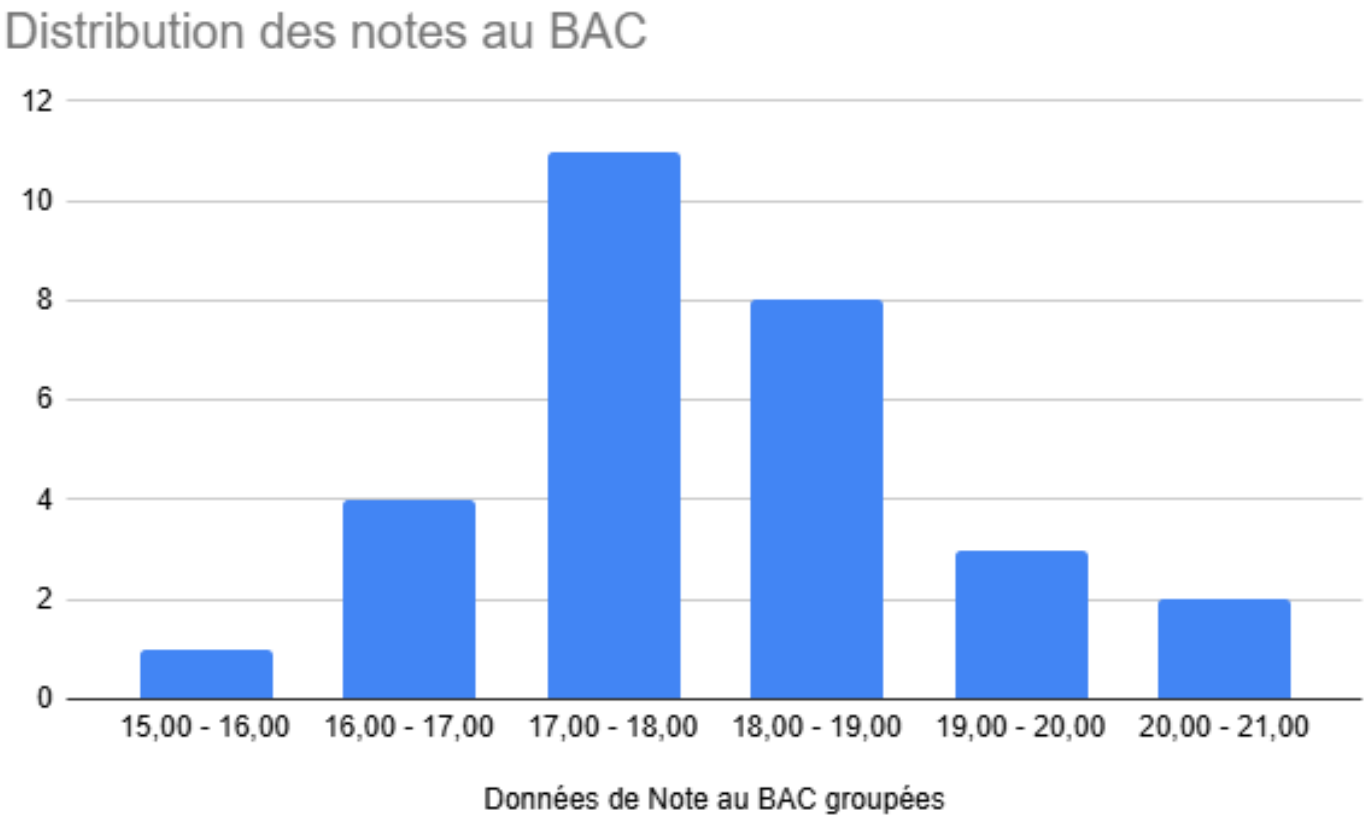

Où est donc le centre de cette distribution ?

Le centre de la distribution

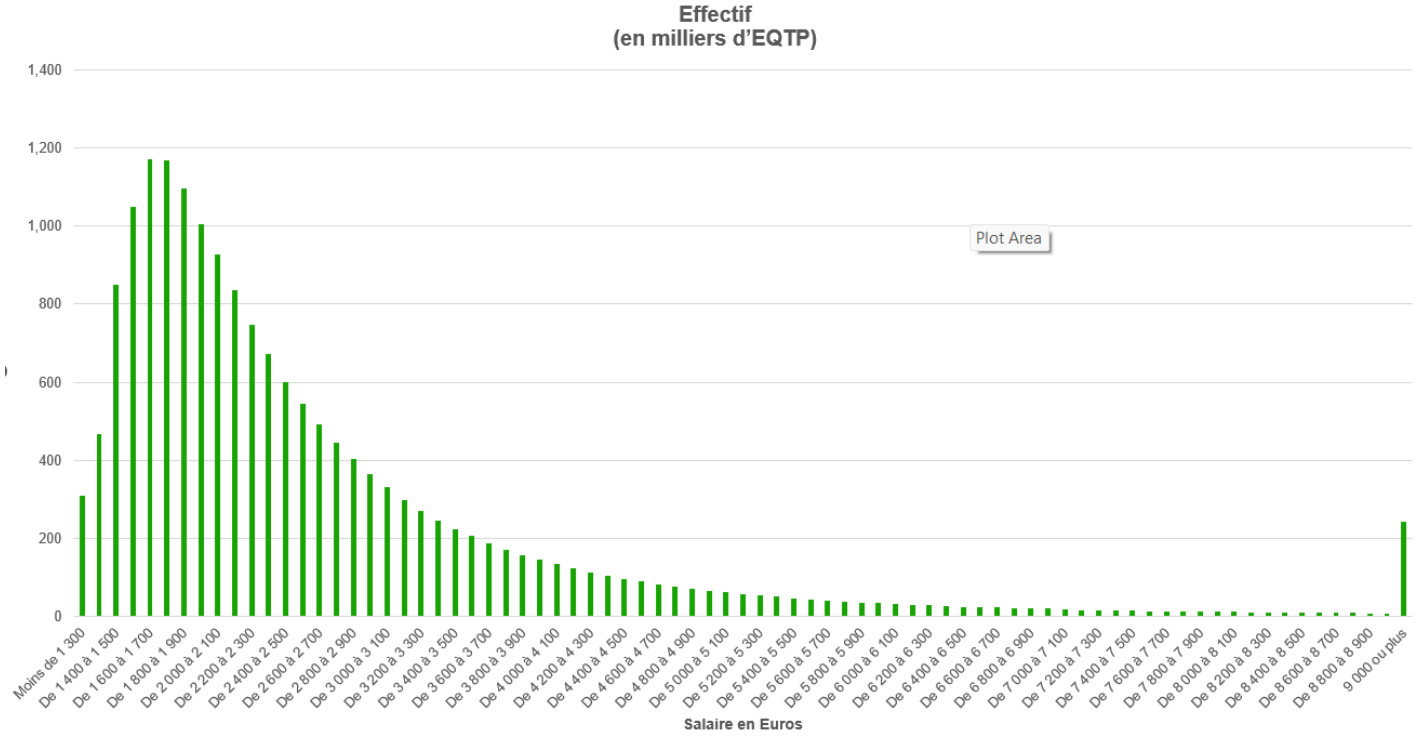

Quid de la distribution des salaires en France ?

Attention à ne pas confondre la **moyenne** avec le **mode**, qui est la valeur la plus fréquente.

SciencesPo

La moyenne de la distribution

- Dans le plus simple des cas, le calcul de la moyenne se fait naturellement en sommant les valeurs puis en divisant par le nombre de valeurs
- Par exemple, si deux parents gagnent 2000 et 3000 euros respectivement, le salaire moyen du couple est de :

$$\frac{2000 + 3000}{1 + 1} = 2500$$

- Plus généralement, la moyenne de plusieurs valeurs est de :

$$Moyenne = \frac{Valeur_1 + Valeur_2 + .. + Valeur_N}{N}$$

En pratique

La fonction MOYENNE permet le calcul direct de la moyenne. Sinon, les fonctions SOMME et NB, sont très utiles pour faire le calcul de façon plus artisanale

La moyenne de la distribution

- En pratique, vous aurez rarement des données au niveau individuel pour éviter le risque de ré-identification.
- En effet, vous serez confronté à des données groupées. Chaque observation regroupera possiblement plusieurs personnes (une entreprise, une zone géographique, une tranche d'âge, etc.)
- En cas de données groupées, la moyenne pondérées, donc qui prend en compte le **poids** de chaque valeur dans l'ensemble:

$$Moyenne = \frac{Poids_1.Valeur_1 + Poids_2.Valeur_2 + .. + Poids_N.Valeur_N}{Poids_1 + Poids_2 + .. + Poids_N}$$

En pratique

La fonction SOMMEPROD qui multiplie différentes varibles, puis somme le produit est très utile pour ce faire

Exemple de calcul de moyenne pondérée

- Si le revenu salarial annuel des hommes est de 26 110 euros et des femmes est de 19 980, ce n'est pas suffisant pour connaître le revenu moyen
- Il faut le pondérer au nombre de femmes (8 millions) et d'hommes (12 millions

$$Revenu_{moyen} = \frac{8M.19980 + 12M.26110}{8M + 12M} = 23658$$

SciencesPo

La médiane de la distribution

- Une autre façon de penser le centre est de penser à l'**observation** du milieu plutôt que la **valeur** du milieu.
- Par exemple: Si on avait le salaire de 100 personnes, le centre pourrait être le salaire de la 50ème personne **dans l'ordre**.
- Cette façon de penser le centre s'appelle la **médiane**.
- La médiane se distingue de la moyenne, principalement par son indépendance des valeurs extrêmes

En pratique

Trouver la médiane peut se faire directement en trouvant l'observation du milieu.

Si le nombre d'observations est pair, la médiane est la moyenne des deux observations du milieu.

La fonction MEDIANE permet le calcul de la médiane.

Exercice 2

Toujours sur les données des notes de l'exercice 1:

1. Calculer la moyenne dans une autre case, en utilisant la fonction MOYENNE
2. Trouver la médiane des notes dans cette classe
3. Recalculer la médiane dans une autre case, en utilisant la fonction MEDIANE
4. Comparer la moyenne à la médiane
5. (Défi) Recalculer la moyenne des notes dans cette classe en utilisant les fonction SOMME et NB .

SciencesPo

Exercice 3

Considérez les données de salaire moyen par département publiées par l'Insee dans la feuille 1:

1. Calculer la moyenne des salaires moyens des départements de France
2. De quoi a-t-on besoin pour calculer est le salaire moyen des français ?
3. Comment rajouter correctement les données de la feuille 2 à la feuille 1 ? Comment s'assurer que ça a bien marché ?
4. Calculer le salaire moyen des français en s'appuyant sur les données de la feuille 1 et 2

SciencesPo

Sommaire

1. Avant-propos
2. Distribution
3. Tendance centrale
4. Dispersion

SciencesPo

Pourquoi s'intéresser à la dispersion

Considérons trois cas de figures des notes (fictives) de trois étudiants:

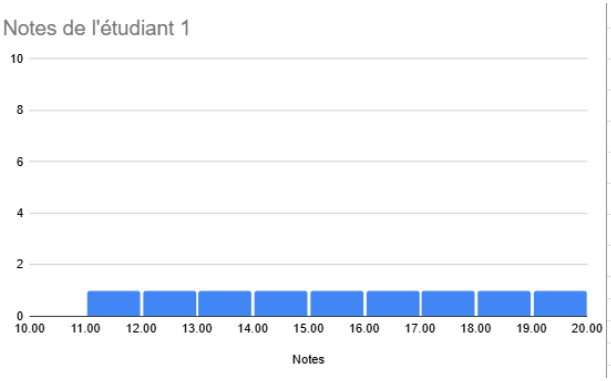

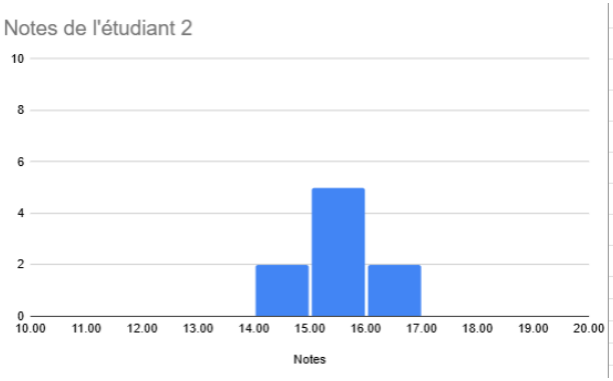

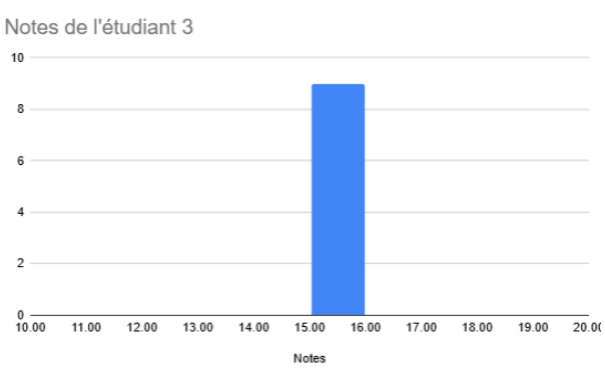

Pourquoi s'intéresser à la dispersion

- Les trois étudiants ont la même moyenne de 15/20
- Cependant, avant de voir les distribution, on aurait pensé que des étudiants avec la même moyenne ont des notes similaires
- En réalité, l'étudiant 1 est très **inconsistent** par exemple, mais il gagnerait à fournir plus d'efforts sur une ou deux matières où ses notes sont les plus basses.
- Contrairement à l'élève 3, qui gagnerait plus à diviser ses effort sur l'ensemble des matières.

SciencesPo

Pourquoi s'intéresser à la dispersion

Mesurer la dispersion reviendrait à mesurer la dispersion l'éloignement des valeurs autour de la moyenne.

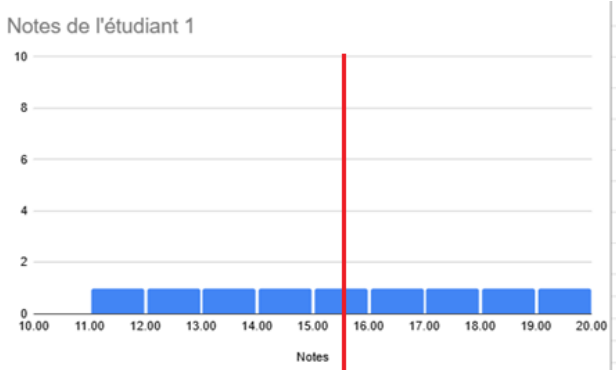

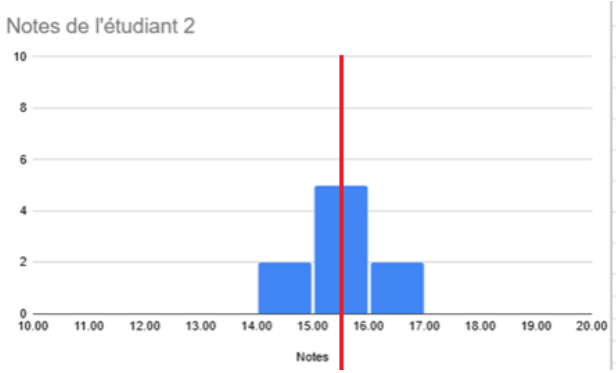

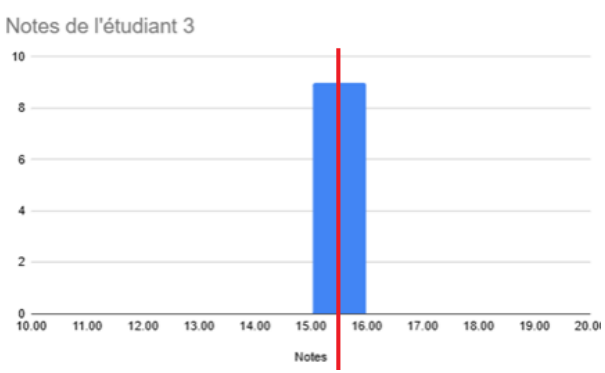

Pourquoi s'intéresser à la dispersion

- Un autre exemple est ceci des différents pays:
- En effet, en Suisse et aux États Unis, le salaire moyen est le même.
- Cependant, le système Suisse étant plus redistributif que celui des États Unis, la distribution des salaires en Suisse est **moins dispersée** qu'aux États-Unis.

La variance de la distribution

- La première mesure de dispersion est **la variance**, qui mesure l'éloignement des valeurs par rapport à la moyenne.
- On calcule valeur par valeur,la somme des carré de la différence, entre la valeur et la moyenne, puis on applique une racine carrée :

$$Variance = \frac{(Valeur_1 - Moyenne)^2 + (Valeur_2 - Moyenne)^2 + ..}{N}$$

En pratique

La fonction VARIANCE permet le calcul de la variance. En pratique, on peut faire le calcul en plusieurs étapes: calculer la différence à la moyenne, puis élever à la puissance carrés, puis enfin appliquer une somme et diviser par le nombre de valeurs.

SciencesPo

Comment voit-on cela pour la distribution des notes en classe ?

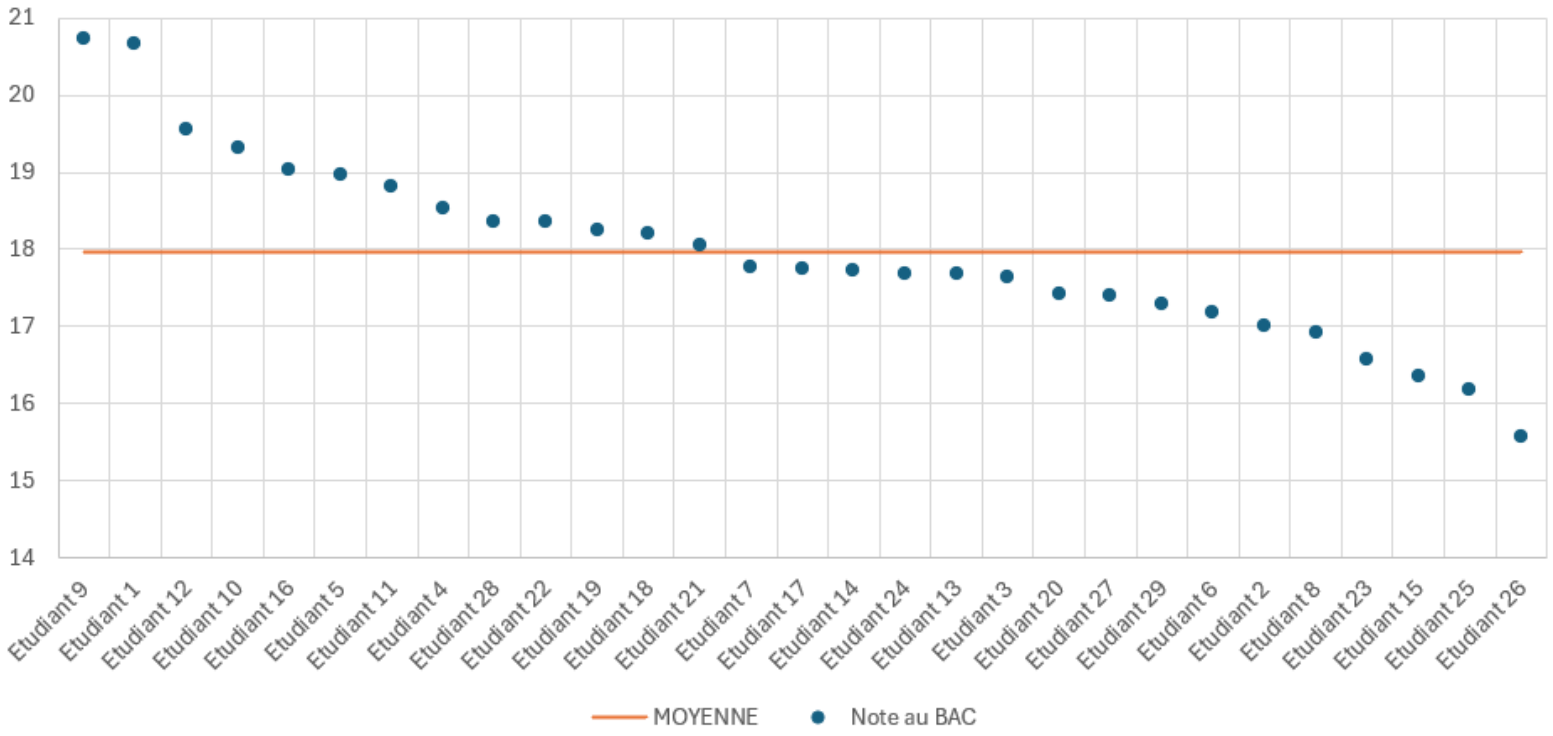

SciencesPo

Comment voit-on cela pour la distribution des notes en classe ?

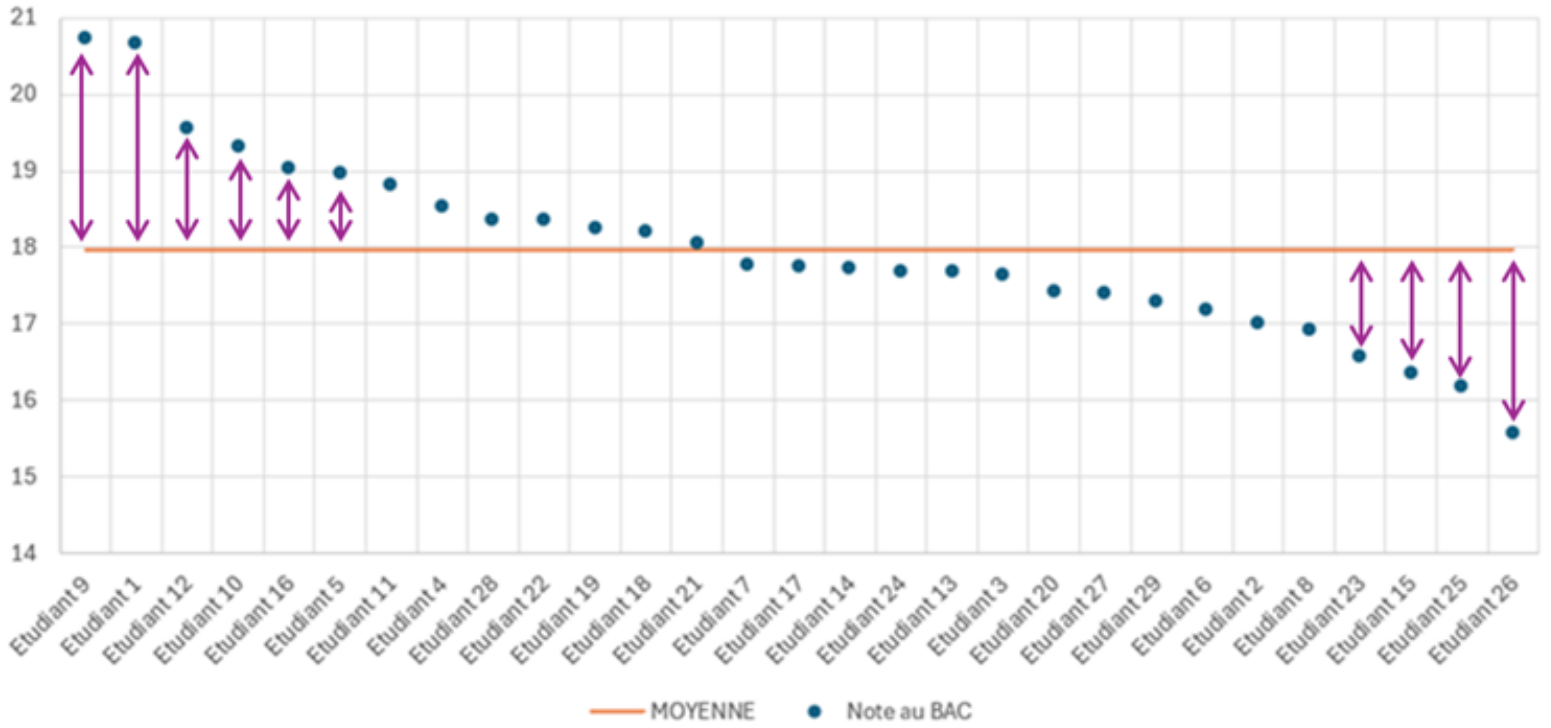

SciencesPo

L'écart-type de la distribution

- Le problème avec la variance est qu'élever à la puissance carrée, faire perdre l'interprétabilité de la données
- La deuxième mesure de dispersion est **l'écart-type**.
-
- On calcule valeur par valeur,la somme des carré de la différence, entre la valeur et la moyenne, puis on applique une racine carrée :

$$Ecart - type = \sqrt{\frac{(Valeur_1 - Moyenne)^2 + (Valeur_2 - Moyenne)^2 + ..}{N}}$$

En pratique

La fonction ECARTYPE permet le calcul de l'écart-type. On peut aussi appliquer la fonction RACINE si l'on a déjà calculé la variance.

SciencesPo

L'écart/rapport interquartile

- Tout comme la médiane qui informe sur l'observation au milieu de la distribution, les quartiles informent sur les personnes au quart, aux deux-quarts (et donc médiane), et aux trois-quarts de la distribution.
- L'écart interquartile est calculé comme la **différence entre le premier quartile** (1/4 de la distribution) et le **troisième quartile** (3/4 de la distribution)
- Le rapport interquartile est semblable, mais remplace la soustraction par une division.

En pratique

La fonction QUARTILE permet d'avoir les trois quartiles comme il faut. Sinon l'observation directe marche aussi.

SciencesPo

Exercice 4

- Calculer la variance de la distribution des notes
- Calculer l'écart-type de la distribution des notes
- Calculer manuellement la variance en montrant les étapes
- Calculer manuellement l'écart-type en partant de la variance
- Trouver les 3 quartiles de la distribution
- Calculer l'écart et le rapport interquartiles

SciencesPo