Méthodes Quantitatives pour les sciences humaines et sociales

Séance 4 : Relier deux variables

Ahmed BAHIAOUI

Sciences Po

janvier-avril 2025

SciencesPo

Sommaire

1. Retour sur le contrôle continu
2. Pourquoi relier des variables ?
3. Quelles types de variables relier?
4. Comment relier les variables?

SciencesPo

Sommaire

1. Retour sur le contrôle continu
2. Pourquoi relier des variables ?
3. Quelles types de variables relier?
4. Comment relier les variables?

SciencesPo

Retour des copies du contrôle continu

Sommaire

1. Retour sur le contrôle continu
2. Pourquoi relier des variables ?
3. Quelles types de variables relier?
4. Comment relier les variables?

SciencesPo

Pourquoi relier des variables

- Jusqu'ici, on s'est intéressé surtout à décrire une variable
- C'est évidemment très informatif, mais pas suffisant
- Pour pousser l'analyse, on essaie souvent de lier une variable que connue, à une variables inconnue
- Ceci est en général, dans des soucis d'une meilleure **compréhension** des variables d'intérêt

SciencesPo

Un exemple de l'intérêt

- La crise Covid a coûté près de 20 Md€ en 2022 en dépenses publiques
- en 2024, on prévoyait y dépenser autour de 1 Md€ seulement
- Comment peut-on arriver à être aussi efficient ?

Un exemple de l'intérêt

- La crise Covid a coûté près de 20 Md€ en 2022 en dépenses publiques
- en 2024, on prévoyait y dépenser autour de 1 Md€ seulement
- Comment peut-on arriver à être aussi efficient ?

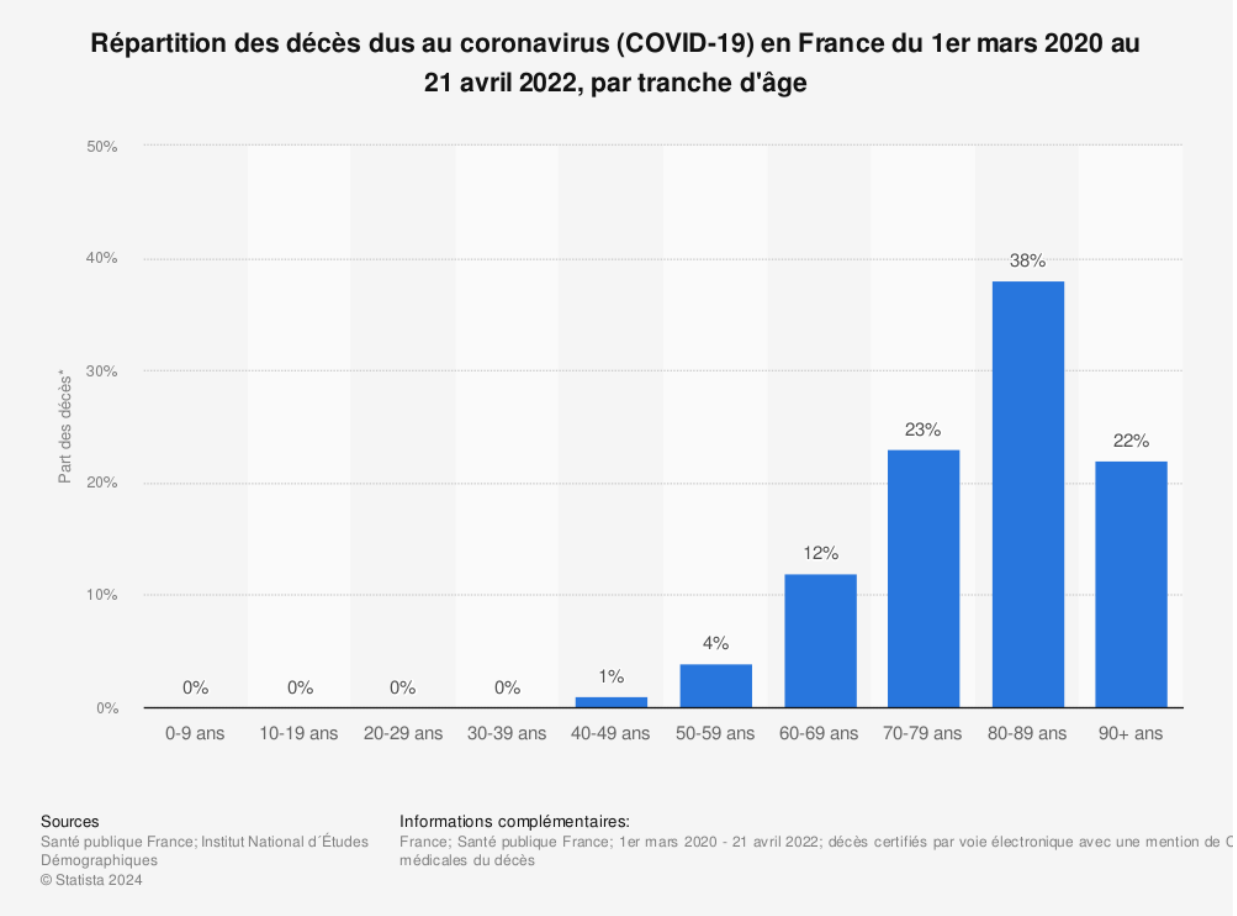

SciencesPo

Un exemple de l'intérêt

- Comprendre le lien entre la mortalité de la Covid et l'âge, a permis de mieux cibler les personnes à risque
- Aujourd'hui, la campagne de vaccination Covid cible en particulier les personnes âgées à cause de leur mortalité élevée (causée par la Covid)

Sommaire

1. Retour sur le contrôle continu
2. Pourquoi relier des variables ?
3. Quelles types de variables relier?
4. Comment relier les variables?

SciencesPo

Principaux types de variables

Nous serons confrontés à deux types de variables :

- Des variables **catégorielles**: Comme la variable "Homme" ou "femme", le situation matrimoniale, ou la catégorie professionnelle.

Principaux types de variables

Nous serons confrontés à deux types de variables :

- Des variables **catégorielles**: Comme la variable "Homme" ou "femme", le situation matrimoniale, ou la catégorie professionnelle.
- Des variables **quantitatives** comme l'âge, le revenu, taille, etc.

Caractériser les variables davantage

- On peut codifier les variables catégorielles, mais cela ne veut pas dire qu'elles deviennent des variables quantitatives (Homme:1, Femme:2)

SciencesPo

Caractériser les variables davantage

- On peut codifier les variables catégorielles, mais cela ne veut pas dire qu'elles deviennent des variables quantitatives (Homme:1, Femme:2)
- Cependant, certaines variables catégorielles sont dites "ordonnées", car l'ordre des valeurs a un sens. (Jamais:1, Parfois:2, Souvent:3, Toujours:4)

SciencesPo

Caractériser les variables davantage

- On peut codifier les variables catégorielles, mais cela ne veut pas dire qu'elles deviennent des variables quantitatives (Homme:1, Femme:2)
- Cependant, certaines variables catégorielles sont dites "ordonnées", car l'ordre des valeurs a un sens. (Jamais:1, Parfois:2, Souvent:3, Toujours:4)
- On peut sinon transformer une variable quantitative en variable catégorielle : Âge $\rightarrow$ Tranches d'âge

SciencesPo

Sommaire

1. Retour sur le contrôle continu
2. Pourquoi relier des variables ?
3. Quelles types de variables relier?
4. Comment relier les variables?

SciencesPo

Le cas simple des variables catégorielles

- Dans le cas des variables catégorielles, aucun calcul mathématique à faire
- Relier les variables revient à voir comment les valeurs sont réparties en fonction des catégories
- Ainsi, deux cas de figure se présentent:

Le cas simple des variables catégorielles

- Dans le cas des variables catégorielles, aucun calcul mathématique à faire
- Relier les variables revient à voir comment les valeurs sont réparties en fonction des catégories
- Ainsi, deux cas de figure se présentent:
  - Pour deux variables catégorielles, on peut regarder une tableau qui regroupe les valeurs croisées entre les deux variables.

SciencesPo

Le cas simple des variables catégorielles

- Dans le cas des variables catégorielles, aucun calcul mathématique à faire
- Relier les variables revient à voir comment les valeurs sont réparties en fonction des catégories
- Ainsi, deux cas de figure se présentent:
  - Pour deux variables catégorielles, on peut regarder une tableau qui regroupe les valeurs croisées entre les deux variables. Cela s'appelle un tableau des effectif, ou ... **tableau croisé** !
  - Dans le cas mixte : On peut toujours présenter les caractéristiques de la variable quantiative, en fonction des catégories de la seconde variables (qui est donc catégorielle). Cela se fait en pratique également avec la fonction tableau dynamique croisé.

SciencesPo

Exemple de Tableau d'effectifs

Case	Gender	Highest level of education
1	Male	College
2	Female	Bachelor
3	Male	Without graduation
4	Male	Master
5	Female	Master
...	...	...

Female and without a degree occurs 6 times in the data

	Female	Male
Without graduation	6	7
College	13	16
Bachelor	16	15
Master	8	11
Total	43	49

SciencesPo

Le cas de deux variables quantitatives

- Dans le cas de deux variables quantitatives, on ne peut pas jouer sur des effectifs
- Pour relier les variables, on s'intéresse à la façon dont les variables **varient ensemble**.
- Ainsi, on calcule donc la **covariance** qui mesure comment les variables bougent ensemble
-

SciencesPo

Comment calculer la covariance ?

- Le calcul de la covariance s'inspire fortement du calcul de la variance.
- Supposons qu'on veuille calculer le covariance du **poids (P)** avec la **taille (T)**.
- La variance du poids est :

$$Variance_{(Poids)} = \frac{(P_1 - P_{moyen})^2 + .. + (P_N - P_{moyen})^2}{N}$$

- La variance de la taille est :

$$Variance_{(Taille)} = \frac{(T_1 - T_{moyen})^2 + .. + (T_N - T_{moyen})^2}{N}$$

SciencesPo

Comment calculer la covariance ?

La covariance est donc obtenu en multipliant les différences à la moyenne de chacune des variables (au lieu des les élever au carré):

$$Covariance_{(P,T)} = \frac{(P_1 - P_{moyen})(T_1 - T_{moyen}) + .. + (P_N - P_{moyen})(T_N - T_{moyen})}{N}$$

En pratique

La fonction COVARIANCE permettrait le calcul de la covariance. En pratique, on peut faire le calcul en plusieurs étapes: calculer la différence à la moyenne, multiplier les différences, puis enfin appliquer une somme et diviser par le nombre de valeurs.*

Attention !

La fonction COVARIANCE sort un résultat de covariance dont le dénominateur est N-1 et non N

SciencesPo

Comment visualiser la covariance

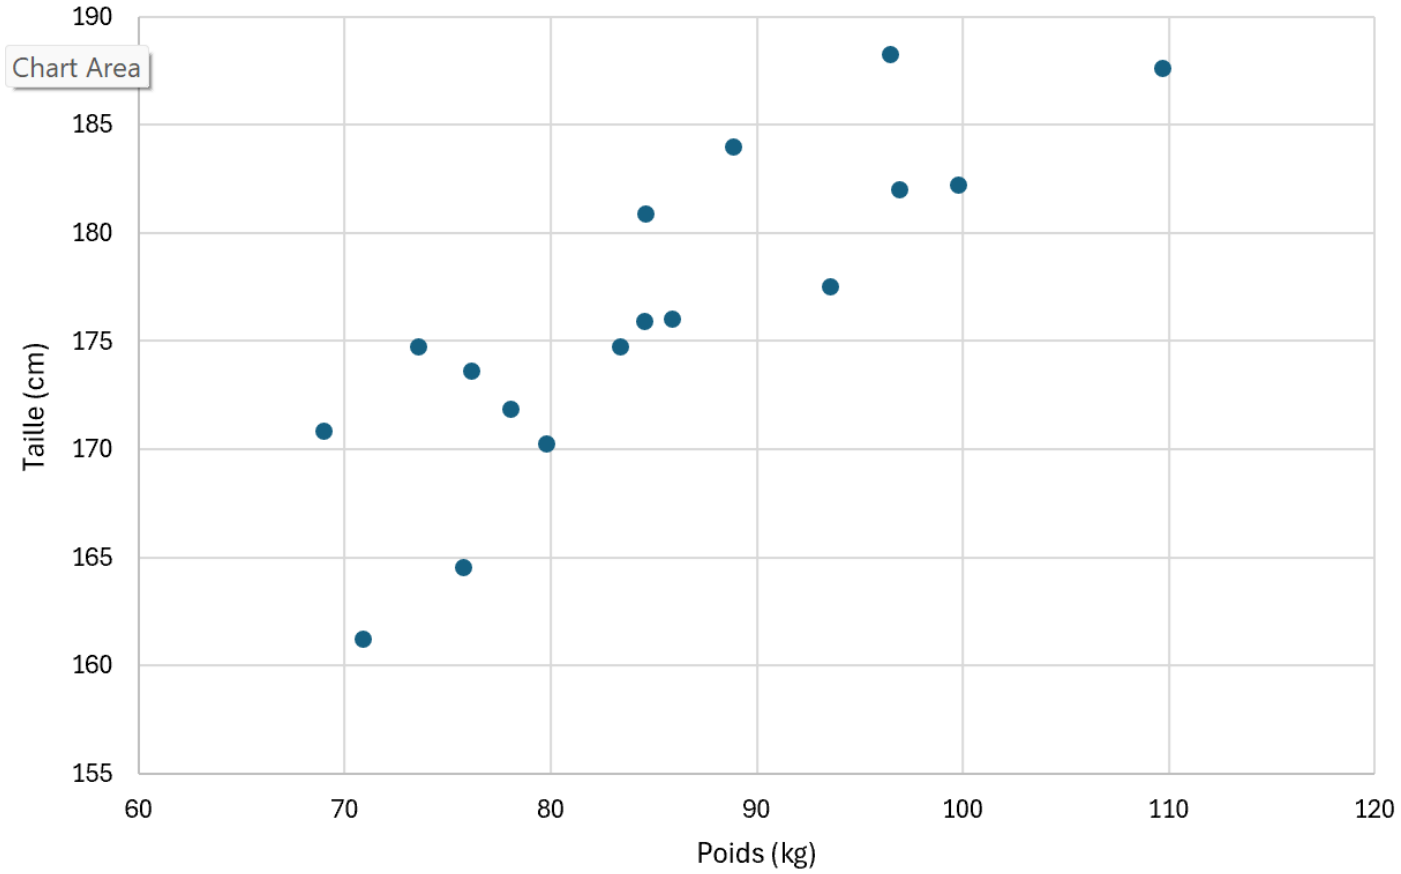

Comment visualiser la covariance

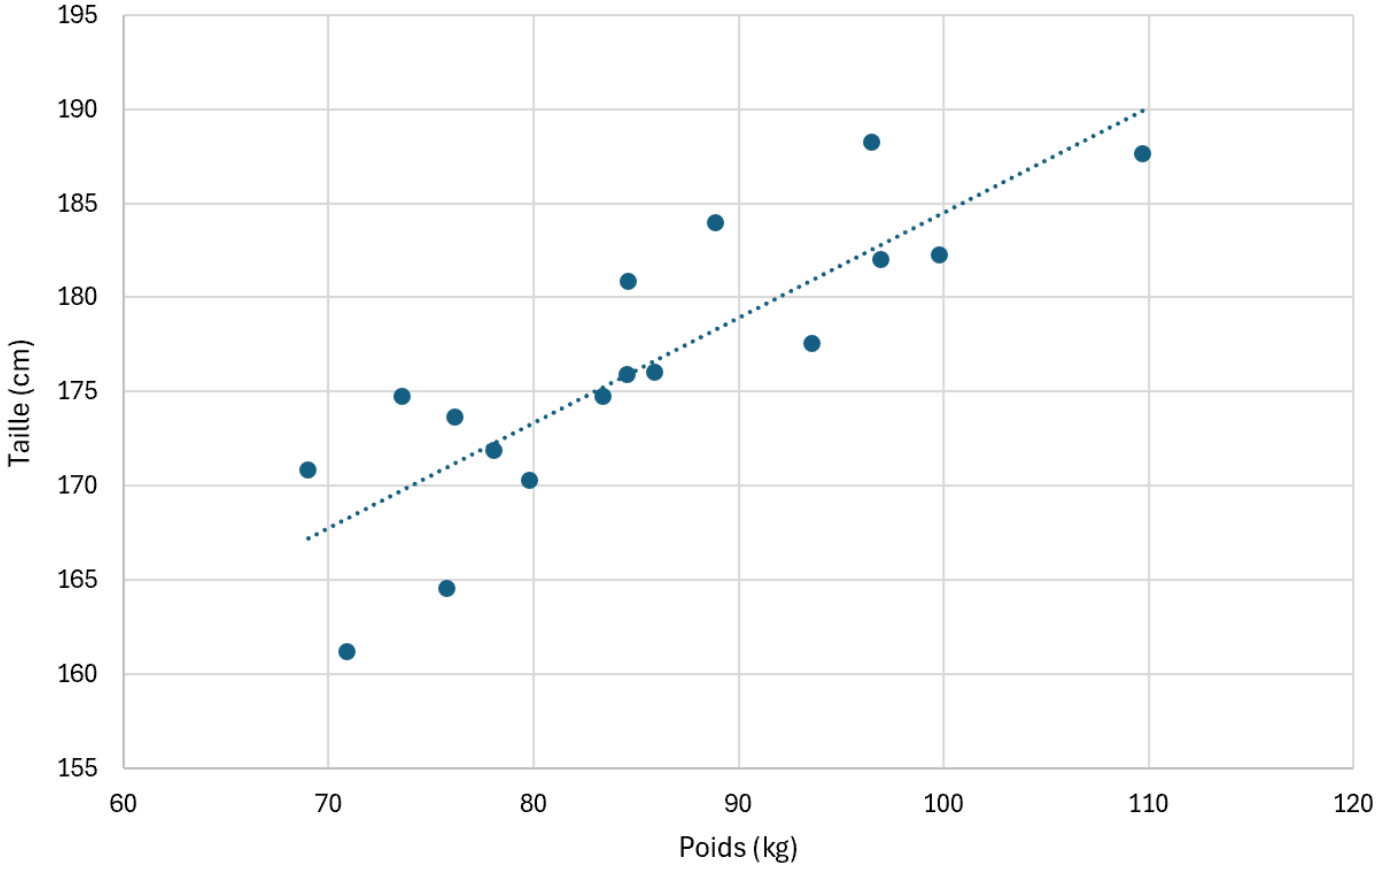

Comment visualiser la covariance

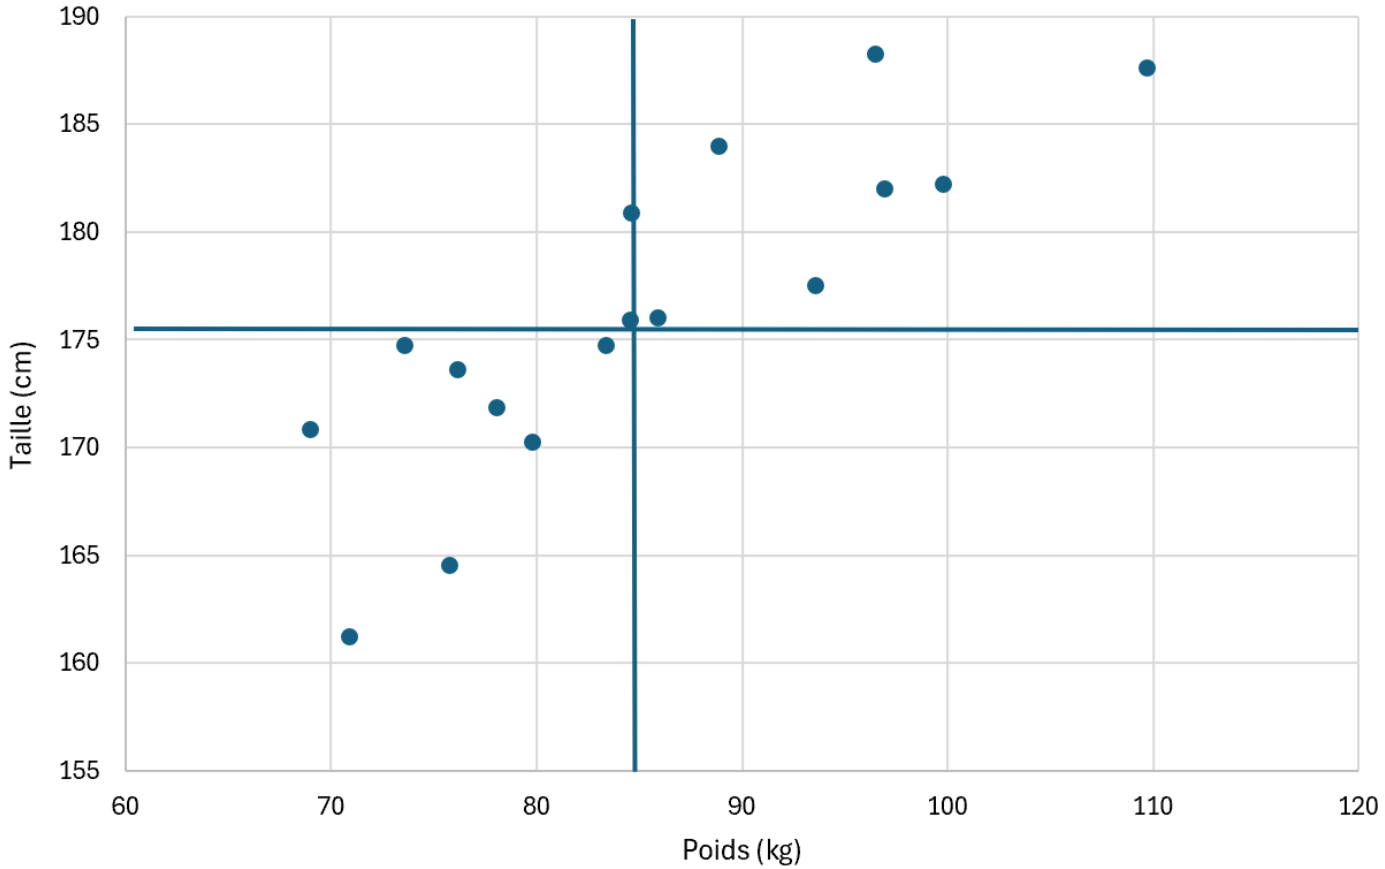

SciencesPo

Comment visualiser la covariance

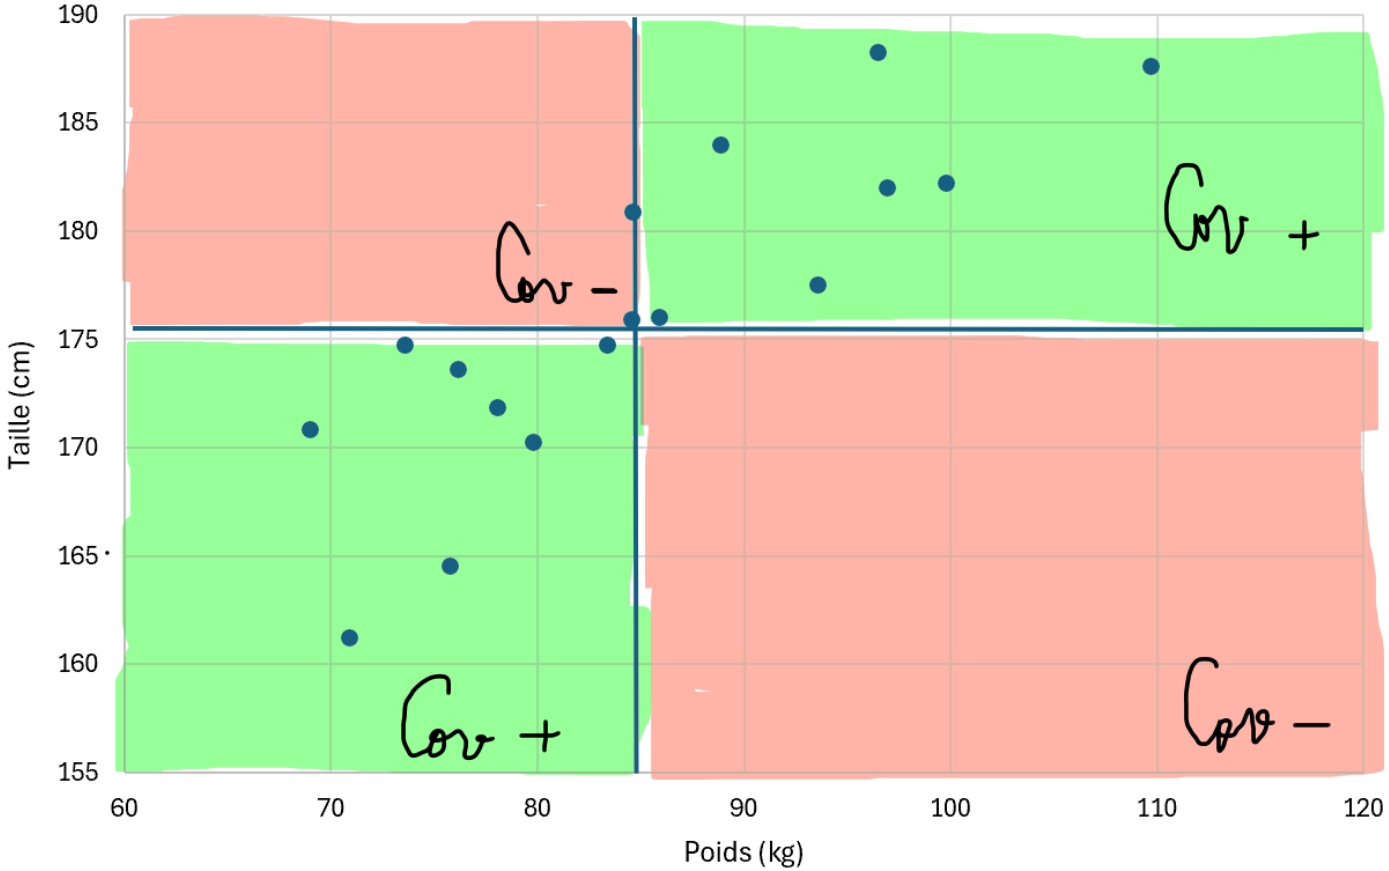

Comment calculer la corrélation ?

Le souci avec la covariance est, comme la variance, le manque d'interprétabilité. Pour y remédier, on divise la covariance par les racines des variances, cela s'appelle la **corrélation**.

$$Correlation_{(P,T)} = \frac{Covariance_{(P,T)}}{\sqrt{Var(P)}.\sqrt{Var(T)}}$$

L'avantage du coefficient de corrélation est que c'est un quantité **sans unité**, qui varie toujours entre **0% (aucune corrélation) et 100% (corrélation parfaite)**.

En pratique

La fonction COEFFICIENT.CORRELATION permet le calcul de la covariance.

Exercice

En utilisant les nouvelles données de notes disponibles ici :

1. Créer un tableau d'effectif de la classe par âge et par sexe.
2. Calculer la note moyenne en mathématiques des hommes et des femmes.
3. Calculer la note moyenne phyique par âge.
4. Calculer la covariance des notes de mathématiques avec les notes de physique.
5. Calculer la corrélation des notes de mathématiques avec les notes de physique.
6. Produisez un nuage de points des notes de physique en fonction des notes de maths. Qu'en pensez-vous?
7. Recalculer la covariance étape par étape.

SciencesPo