Méthodes Quantitatives pour les sciences humaines et sociales

Séance 5 : D'où viennent les données statistiques

Ahmed BAHIAOUI

Sciences Po

janvier-avril 2025

SciencesPo

Sommaire

1. Avant-propos
2. Motivation de la question
3. Les sources des données
4. L'échantillonnage

SciencesPo

Sommaire

1. Avant-propos
2. Motivation de la question
3. Les sources des données
4. L'échantillonnage

SciencesPo

Rappel :
Contrôle continu N°2 la prochaine séance.

Sommaire

1. Avant-propos
2. Motivation de la question
3. Les sources des données
4. L'échantillonnage

SciencesPo

L'exemple des données de délinquance

FIGURE I. – ***Cambriolages (1984-2005)*** *(en milliers)*

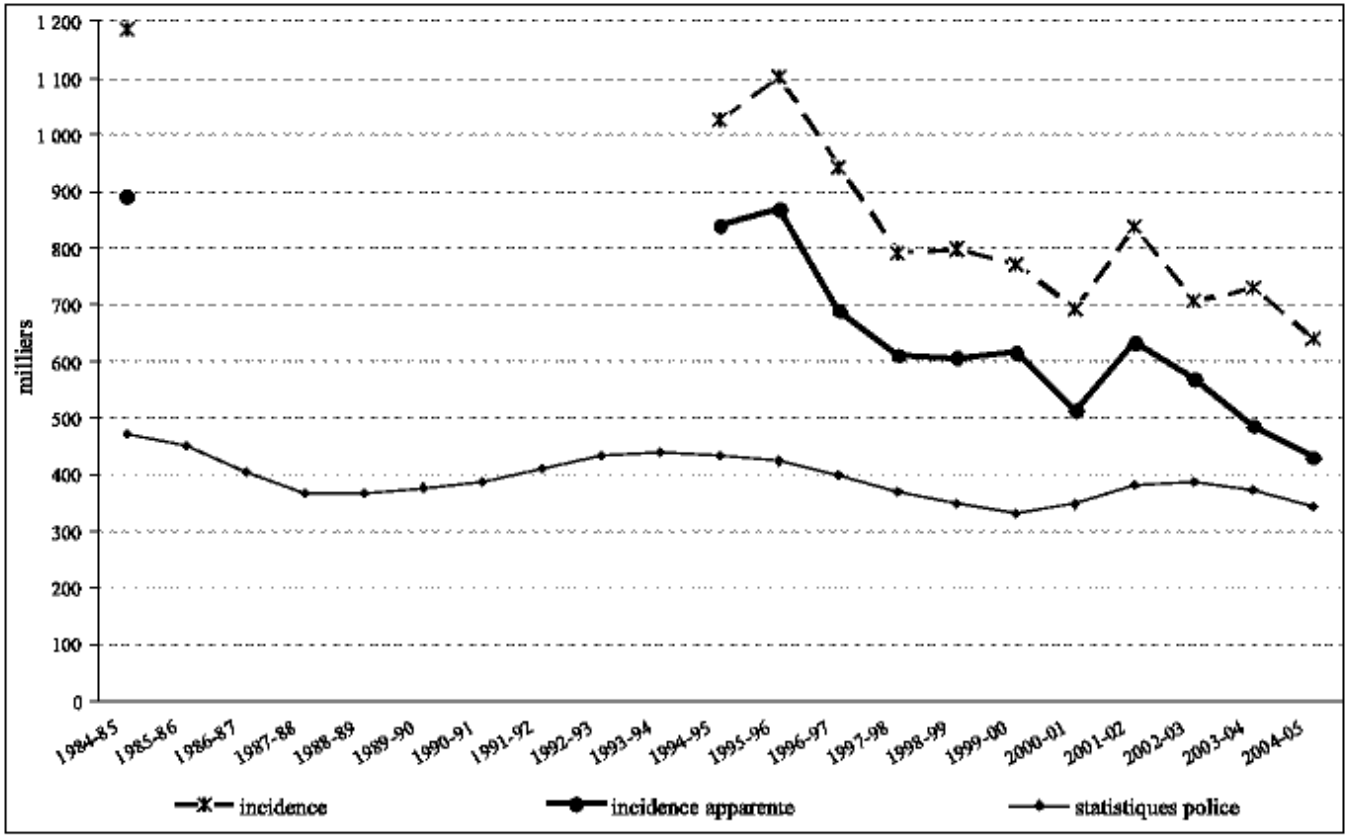

Source : Cesdip, Insee, ministère de l'Intérieur.
Champ : France hexagonale.

L'importance des sources dans le débat social

- Ces séries sont sourcées différemment :

L'importance des sources dans le débat social

- Ces séries sont sourcées différemment :
  - Même si on mesure la même information, la différence dans le traitement peut induire des différences

SciencesPo

L'importance des sources dans le débat social

- Ces séries sont sourcées différemment :
  - Même si on mesure la même information, la différence dans le traitement peut induire des différences
- Selon la série de données retenues, on peut tirer des conclusions différentes

Pourquoi ces différences existent-elles ?

Sommaire

1. Avant-propos
2. Motivation de la question
3. Les sources des données
4. L'échantillonnage

SciencesPo

Les grands types de sources de données (sociales)

- En fonction de leurs sources, on peut classifier les données en :
  - **Données administratives**
  - **Données d'enquêtes**
  - **Données issues de traces**

Les données administratives

- Les données administratives sont :

Les données administratives

- Les données administratives sont :
  - Produites par les administrations et les entreprises

SciencesPo

Les données administratives

- Les données administratives sont :
  - Produites par les administrations et les entreprises
  - Assez fiables et surtout **exhaustives**

SciencesPo

Les données administratives

- Les données administratives sont :
  - Produites par les administrations et les entreprises
  - Assez fiables et surtout **exhaustives**
  - Peu flexibles sur leur collecte

Les données administratives

- Les données administratives sont :
  - Produites par les administrations et les entreprises
  - Assez fiables et surtout **exhaustives**
  - Peu flexibles sur leur collecte
- Exemples : Données fiscales, données du registre du commerce, etc.

SciencesPo

Les données d'enquêtes

- Les données d'enquêtes sont :

Les données d'enquêtes

- Les données d'enquêtes sont :
  - Recueillies au moyen de **sondages ou interviews**

Les données d'enquêtes

- Les données d'enquêtes sont :
  - Recueillies au moyen de **sondages ou interviews**
  - Souvent riches en informations qualitatives

SciencesPo

Les données d'enquêtes

- Les données d'enquêtes sont :
  - Recueillies au moyen de **sondages ou interviews**
  - Souvent riches en informations qualitatives
  - Non-exhaustives et souvent restreintes à un **échantillon**

SciencesPo

Les données d'enquêtes

- Les données d'enquêtes sont :
  - Recueillies au moyen de **sondages ou interviews**
  - Souvent riches en informations qualitatives
  - Non-exhaustives et souvent restreintes à un **échantillon**
- Exemple : Sondages politiques, enquêtes de satisfaction, etc.

SciencesPo

Les données issues de traces

- Les données issues de traces sont:
  - généralement captées **sans intention première d'analyse**

SciencesPo

Les données issues de traces

- Les données issues de traces sont:
  - généralement captées **sans intention première d'analyse**
  - Souvent des volumes de données importants

SciencesPo

Les données issues de traces

- Les données issues de traces sont:
  - généralement captées **sans intention première d'analyse**
  - Souvent des volumes de données importants
  - Préoccupations liées à l'éthique et à la confidentialité

SciencesPo

Les données issues de traces

- Les données issues de traces sont:
  - généralement captées **sans intention première d'analyse**
  - Souvent des volumes de données importants
  - Préoccupations liées à l'éthique et à la confidentialité
- Exemples : Historique d'achats, posts sur réseaux sociaux

SciencesPo

Exercice:

Pour chacune des données suivantes, déterminer le type de sources de données, et les sources de biaux possibles.

Exemple 1

Graphique 1 • Âge moyen de départ et âge moyen de départ corrigé des retraites anticipées, au régime général

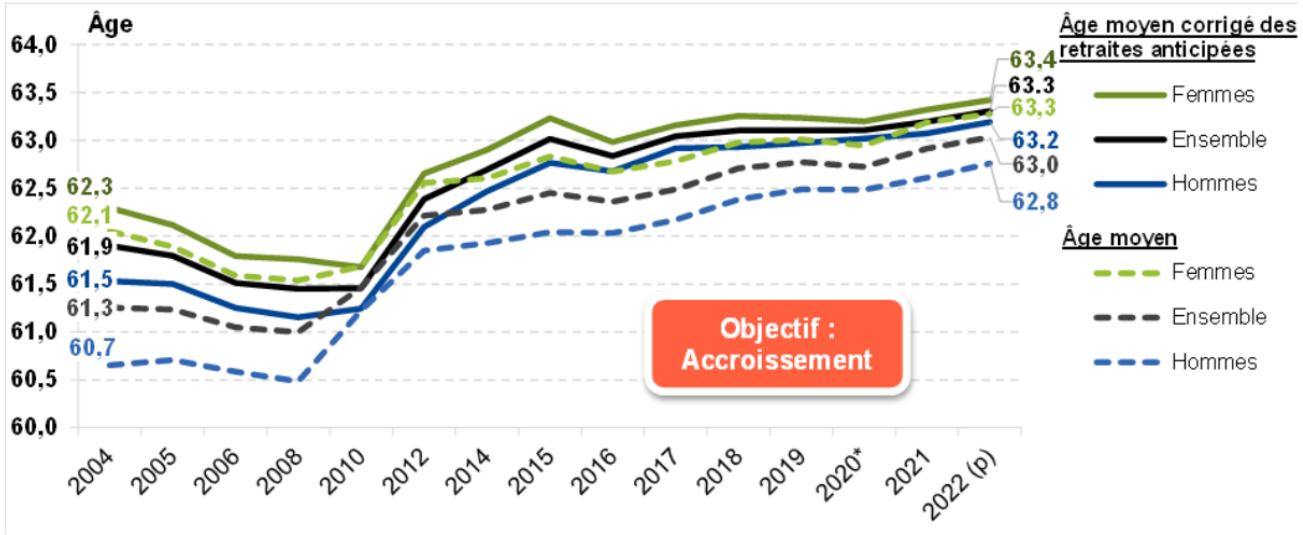

(p) : prévision

Remarque : Entre 2004 et 2019, sont comptabilisés les retraités anciens travailleurs salariés. A partir de 2020* sont comptabilisés les retraités anciens travailleurs salariés et indépendants

Source : CNAV.

Exemple 2

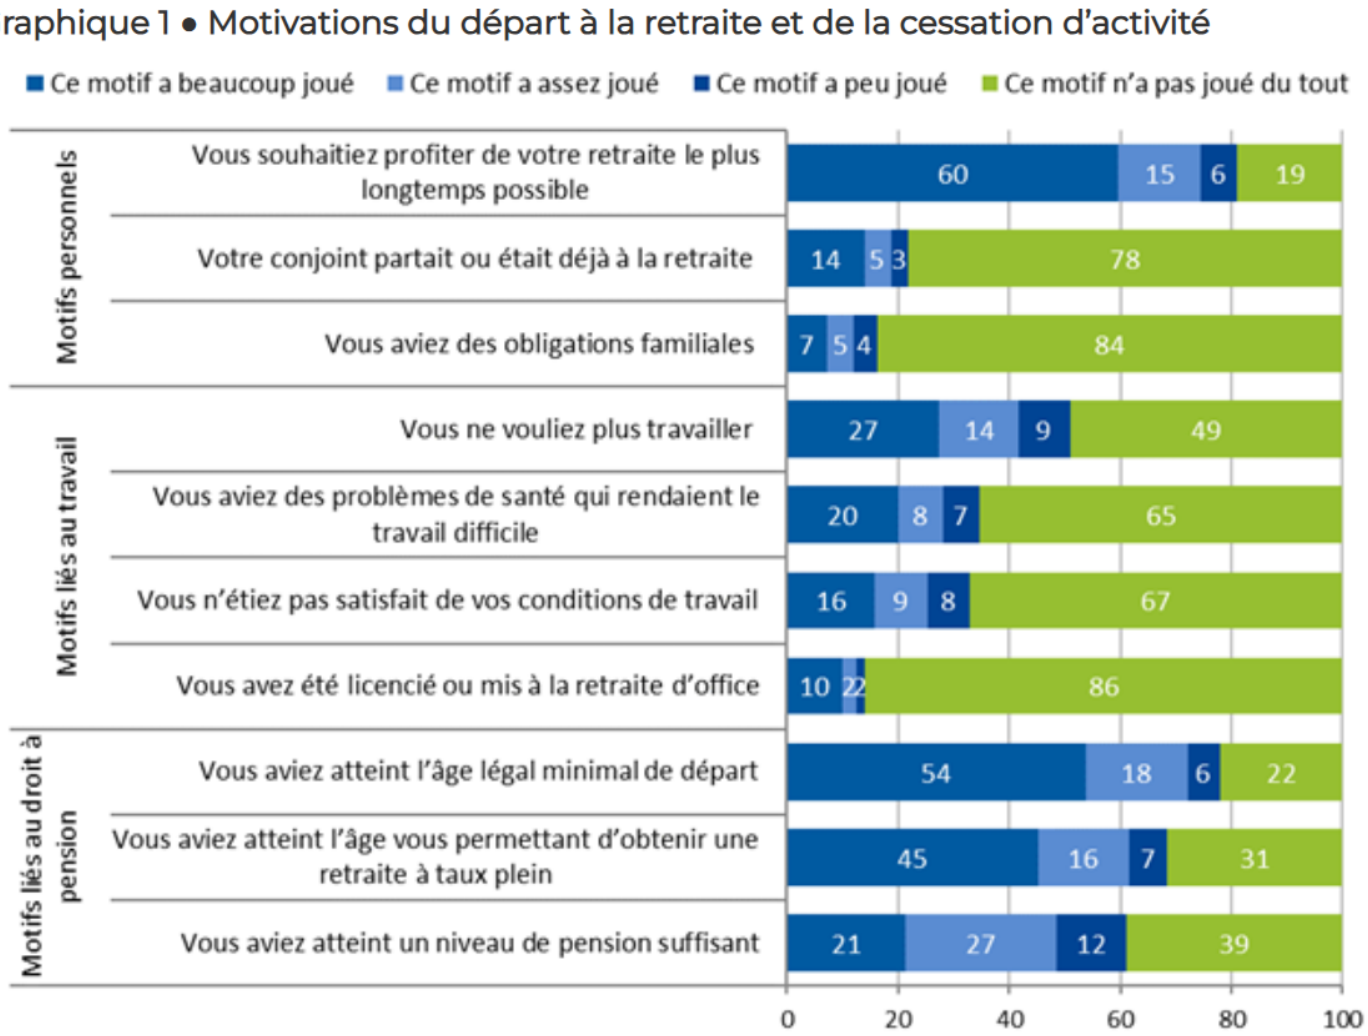
Graphique 1 • Motivations du départ à la retraite et de la cessation d'activité
Ce motif a beaucoup joué
Ce motif a assez joué
Ce motif a peu joué
Ce motif n'a pas joué du tout
Motifs personnels
Vous souhaitiez profiter de votre retraite le plus longtemps possible
60 15 6 19
Votre conjoint partait ou était déjà à la retraite
14 5 3 78
Vous aviez des obligations familiales
7 5 4 84
Motifs liés au travail
Vous ne vouliez plus travailler
27 14 9 49
Vous aviez des problèmes de santé qui rendaient le travail difficile
20 8 7 65
Vous n'étiez pas satisfait de vos conditions de travail
16 9 8 67
Vous avez été licencié ou mis à la retraite d'office
10 2 2 86
Motifs liés au droit à pension
Vous aviez atteint l'âge légal minimal de départ
54 18 6 22
Vous aviez atteint l'âge vous permettant d'obtenir une retraite à taux plein
45 16 7 31
Vous aviez atteint un niveau de pension suffisant
21 27 12 39
0 20 40 60 80 100

Exemple 3

Graphique 1 • Nombre annuel de consultations de médecins par habitant 2010-2021

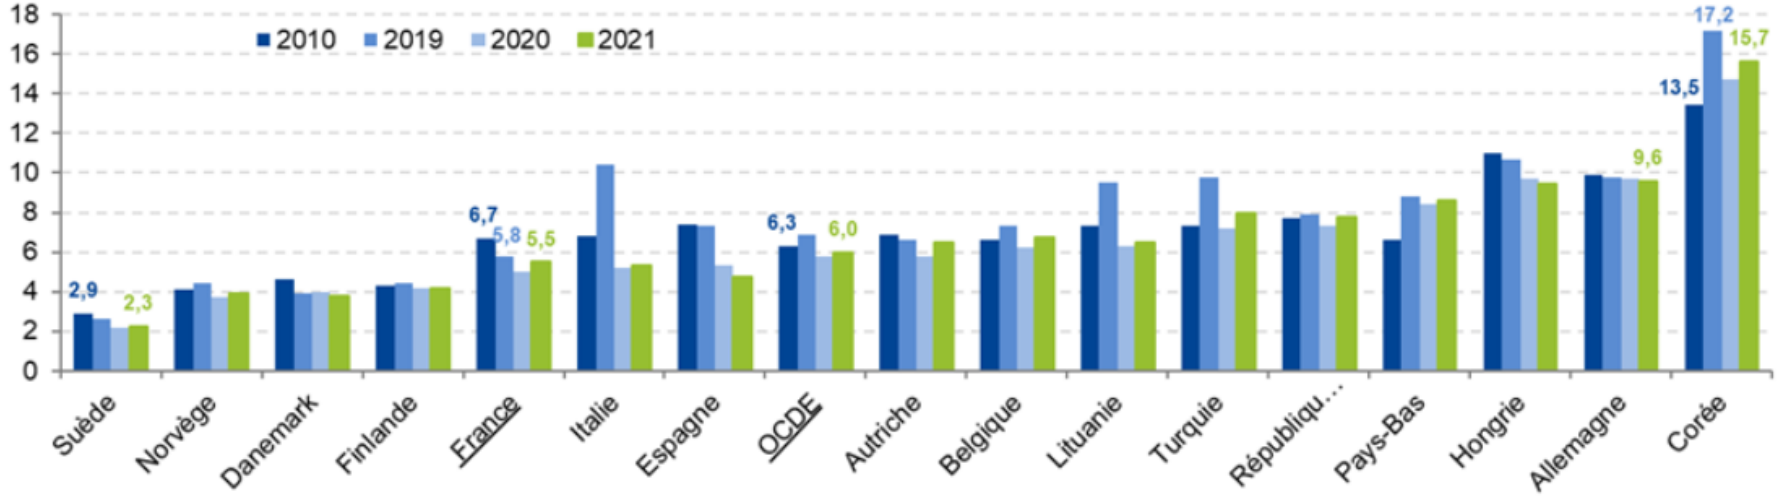

Source : OCDE 2021

SciencesPo

Exemple 4

Graphique 3 • Nombre de comptes personnels de retraite

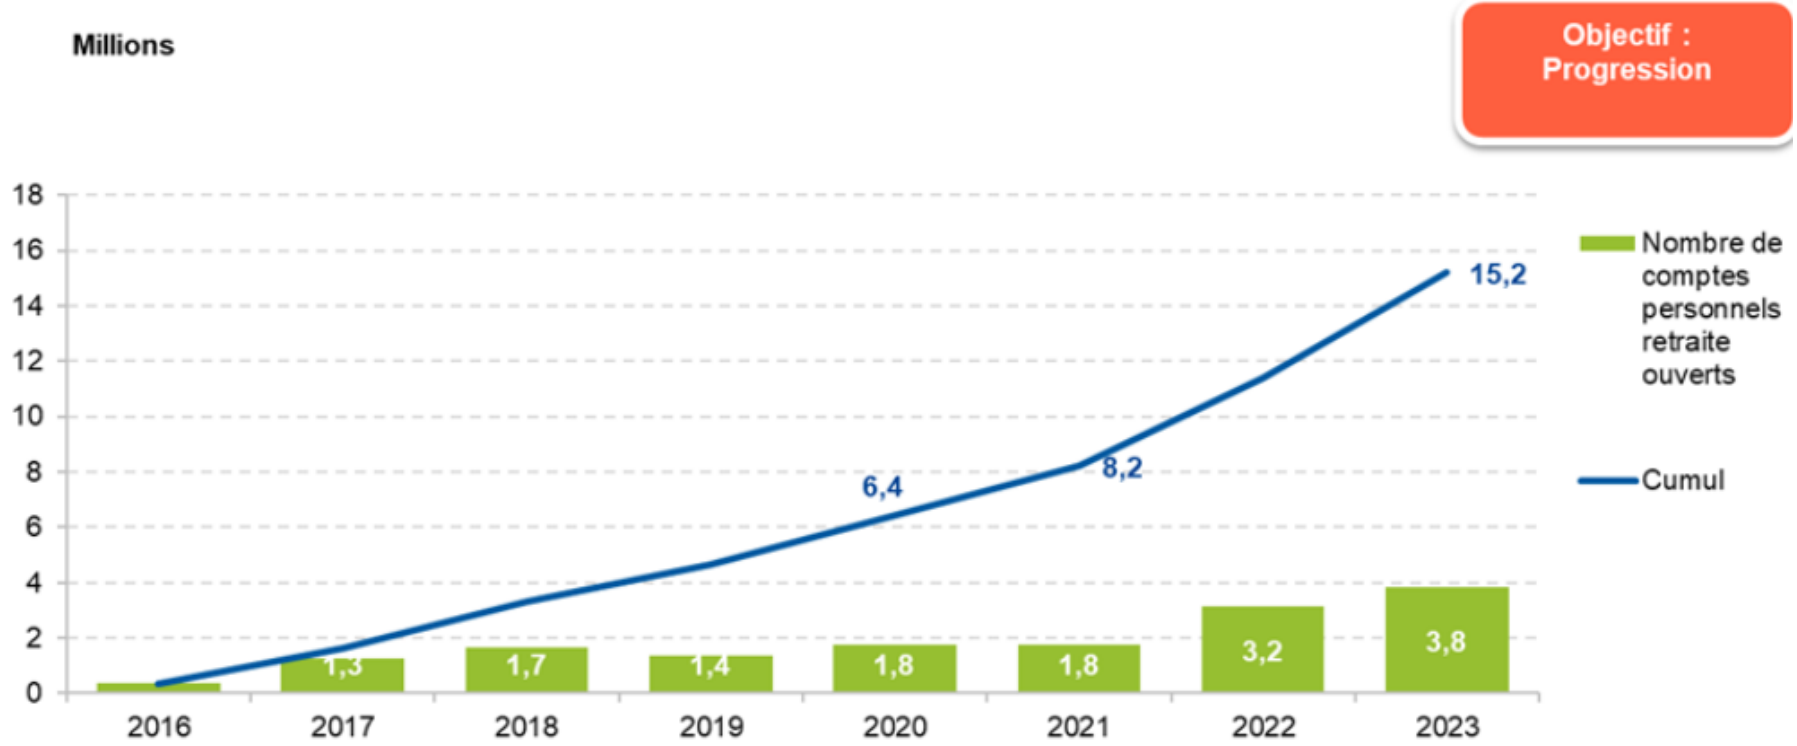

Source : GIP Union Retraite.

SciencesPo

Sommaire

1. Avant-propos
2. Motivation de la question
3. Les sources des données
4. L'échantillonnage

SciencesPo

L'enjeu de l'échantillonnage

En 1936, l'hebdomadaire *The Literary Digest*, prédit une défaite de Franklin D Roosevelt dans les élections présidentielles américaines avec 43% du vote populaire.

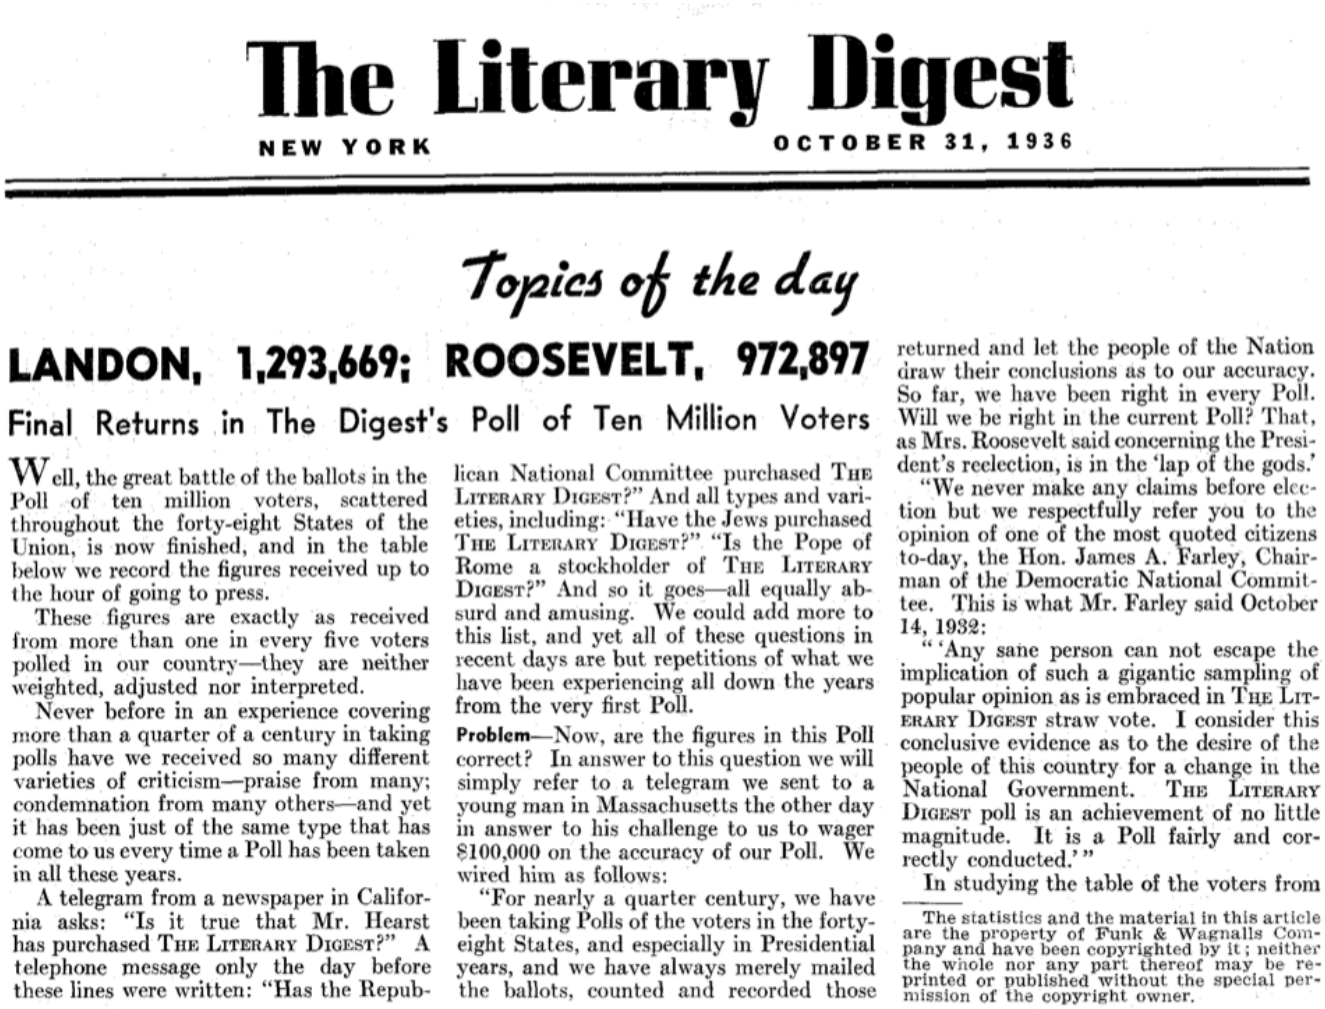

The Literary Digest

NEW YORK — OCTOBER 31, 1936

Topics of the day

LANDON, 1,293,669; ROOSEVELT, 972,897

Final Returns in The Digest's Poll of Ten Million Voters

Well, the great battle of the ballots in the Poll of ten million voters, scattered throughout the forty-eight States of the Union, is now finished, and in the table below we record the figures received up to the hour of going to press.

These figures are exactly as received from more than one in every five voters polled in our country—they are neither weighted, adjusted nor interpreted.

Never before in an experience covering more than a quarter of a century in taking polls have we received so many different varieties of criticism—praise from many; condemnation from many others—and yet it has been just of the same type that has come to us every time a Poll has been taken in all these years.

A telegram from a newspaper in California asks: "Is it true that Mr. Hearst has purchased THE LITERARY DIGEST?" A telephone message only the day before these lines were written: "Has the Republican National Committee purchased THE LITERARY DIGEST?" And all types and varieties, including: "Have the Jews purchased THE LITERARY DIGEST?" "Is the Pope of Rome a stockholder of THE LITERARY DIGEST?" And so it goes—all equally absurd and amusing. We could add more to this list, and yet all of these questions in recent days are but repetitions of what we have been experiencing all down the years from the very first Poll.

Problem—Now, are the figures in this Poll correct? In answer to this question we will simply refer to a telegram we sent to a young man in Massachusetts the other day in answer to his challenge to us to wager $100,000 on the accuracy of our Poll. We wired him as follows:

"For nearly a quarter century, we have been taking Polls of the voters in the forty-eight States, and especially in Presidential years, and we have always merely mailed the ballots, counted and recorded those returned and let the people of the Nation draw their conclusions as to our accuracy. So far, we have been right in every Poll. Will we be right in the current Poll? That, as Mrs. Roosevelt said concerning the President's reelection, is in the 'lap of the gods.'

"We never make any claims before election but we respectfully refer you to the opinion of one of the most quoted citizens to-day, the Hon. James A. Farley, Chairman of the Democratic National Committee. This is what Mr. Farley said October 14, 1932:

"'Any sane person can not escape the implication of such a gigantic sampling of popular opinion as is embraced in THE LITERARY DIGEST straw vote. I consider this conclusive evidence as to the desire of the people of this country for a change in the National Government. THE LITERARY DIGEST poll is an achievement of no little magnitude. It is a Poll fairly and correctly conducted.'"

In studying the table of the voters from

The statistics and the material in this article are the property of Funk & Wagnalls Company and have been copyrighted by it; neither the whole nor any part thereof may be reprinted or published without the special permission of the copyright owner.

L'enjeu de l'échantillonnage

En réalité, Roosevelt gagnera l'élection avec 62% du vote populaire dans une des plus grandes victoires des élections américaines. Le magazine fera faillite suite à ce résultat catastrophique.

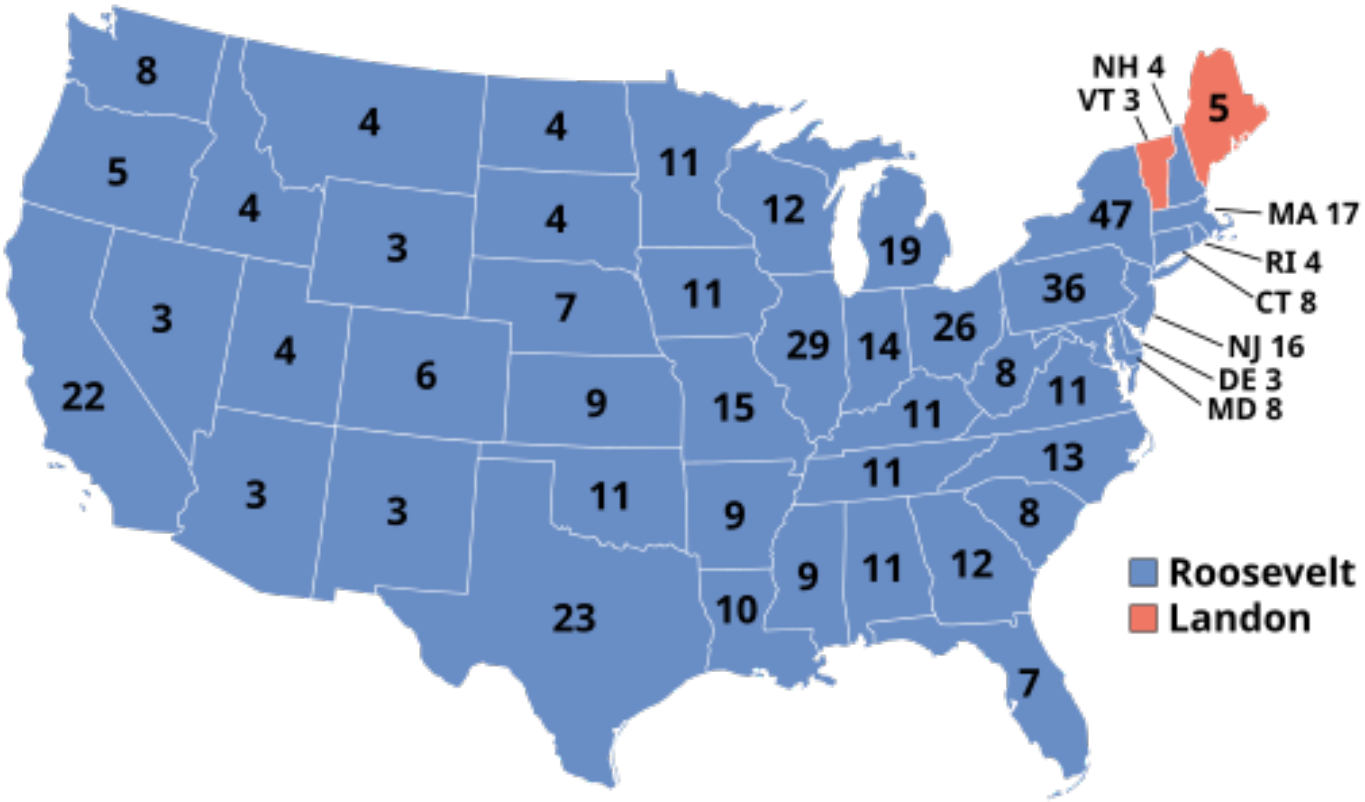

SciencesPo

Comment échantillonner ?

- Le fait que les données issues d'enquêtes ne sont pas exhaustives impose la question :
  - Comment choisir les entités (personnes, entreprises, etc.) à qui nous poseront les questions de notre enquête ?
  - Peut-on garantir que ces réponses seront **représentatives de la population étudiée** ?
- Le processus du choix de ces personnes parmi **la population** étudiée s'appelle **l'échantillonnage**. Une fois défini, ce groupe de personne s'appelle **l'échantillon**
- Ce processus a des conséquences importantes sur les résultats obtenus.

SciencesPo

L'échantillonnage aléatoire

Le premier réflexe est donc de choisir aléatoirement l'échantillon parmi la population :

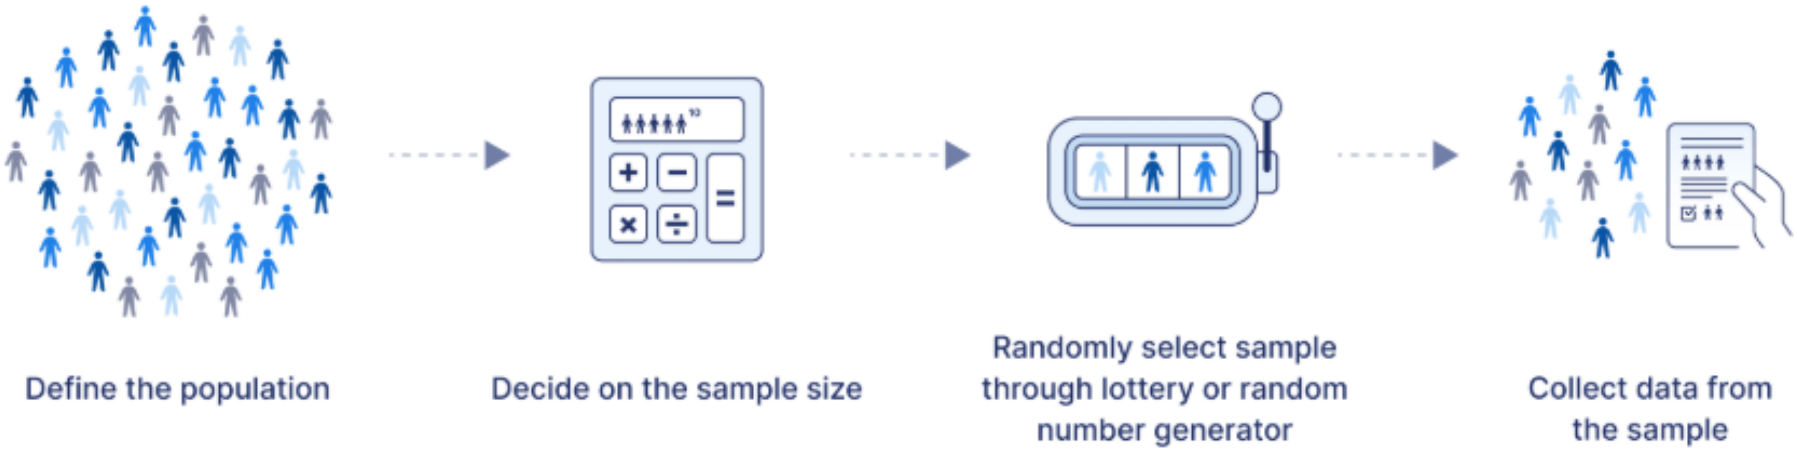

L'échantillonnage aléatoire

Le premier réflexe est donc de choisir aléatoirement l'échantillon parmi la population :

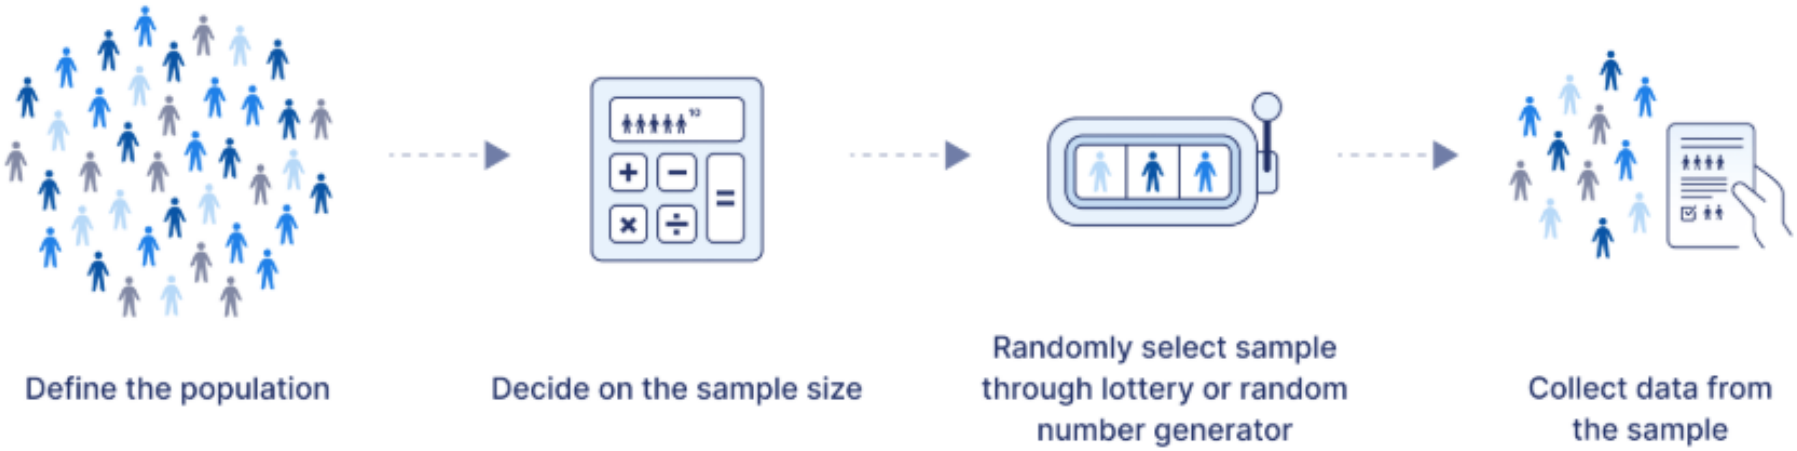

Cependant, cela n'aboutit pas toujours à un échantillon représentatif de la population

L'échantillonnage aléatoire en pratique

L'échantillonnage aléatoire en pratique

Plusieurs méthodes se posent pour effectuer un échantillonnage aléatoire en pratique, elles reposent principalement sur la fonction ALEA qui permet de générer des nombres aléatoires. La méthode la plus simple serait d'assigner des nombres aléatoires à chaque observation à l'aide de cette fonction, de réordonner les données suivant le nombre aléatoire assigné, puis de choisir les 100 (ou 1000, ou quelconque taille d'échantillon) premières observations.

L'échantillonnage aléatoire stratifié

Dans certains cas, on voudrait s'assurer que certaines **catégories** sont bien représentées dans notre échantillon. Dans ce cas là, on choisit aléatoirement dans chacune de ces catégories (ou **stratum**) pour aboutir à un échantillon où toutes les catégories sont représentées

On appelle cela une échantillonnage aléatoire **stratifié**.

La qualité d'échantillonnage

- La qualité de l'échantillonnage, contre-intuitivement, ne correspond pas au ratio de de l'échantillon dans la population.
- Elle correspond surtout à la taille de l'échantillon dans l'absolu.
- Pour un minimum de représentativité, une taille minimum d'échantillon est nécessaire, indépendamment de la taille de la population

SciencesPo