

Méthodes Quantitatives pour les sciences humaines et sociales

Séance 6 : Construire une base de données

Ahmed BAHIAOUI

Sciences Po

janvier-avril 2026

SciencesPo

- 1 Avant propos
- 2 Les méthodes d'échantillonnage
- 3 Comment construire un questionnaire ?
- 4 Comment exploiter les traces ?
- 5 Le recodage des variables

- 1 Avant propos
- 2 Les méthodes d'échantillonnage
- 3 Comment construire un questionnaire ?
- 4 Comment exploiter les traces ?
- 5 Le recodage des variables

Rappel sur les sources de données

Comme discuté la séance précédente, il existe trois principaux types de sources de données :

- Les données administratives
- Les données issues de traces
- Les données d'enquêtes

Rappel sur les sources de données

Comme discuté la séance précédente, il existe trois principaux types de sources de données :

- Les données administratives
- Les données issues de traces
- Les données d'enquêtes

Les données d'enquêtes sont principalement celles qu'on peut décider de construire et collecter nous-mêmes !

- 1 Avant propos
- 2 Les méthodes d'échantillonnage
- 3 Comment construire un questionnaire ?
- 4 Comment exploiter les traces ?
- 5 Le recodage des variables

Rappel : Échantillonnage aléatoire et stratifié

- **L'échantillonnage aléatoire simple** : Chaque individu de la population cible a exactement la même probabilité d'être tiré au sort.
 - *Condition* : Nécessite de posséder une base de sondage exhaustive.

Rappel : Échantillonnage aléatoire et stratifié

- **L'échantillonnage aléatoire simple** : Chaque individu de la population cible a exactement la même probabilité d'être tiré au sort.
 - *Condition* : Nécessite de posséder une base de sondage exhaustive.
- **L'échantillonnage stratifié** : La population est divisée en sous-groupes homogènes (les strates, ex: sexe, âge). On effectue ensuite un tirage aléatoire au sein de chaque strate.
 - *Avantage* : Assure une représentativité parfaite sur les variables choisies pour créer les strates (très utile pour garantir des quotas précis).

L'échantillonnage systématique

- **Le principe :** Tirer un individu tous les k pas dans une base de sondage (ex: sélectionner un étudiant sur 10 dans une liste alphabétique).

L'échantillonnage systématique

- **Le principe** : Tirer un individu tous les k pas dans une base de sondage (ex: sélectionner un étudiant sur 10 dans une liste alphabétique).
- **Avantage** : Très simple et rapide à mettre en œuvre lorsque l'on dispose d'une liste exhaustive de la population.

L'échantillonnage systématique

- **Le principe** : Tirer un individu tous les k pas dans une base de sondage (ex: sélectionner un étudiant sur 10 dans une liste alphabétique).
- **Avantage** : Très simple et rapide à mettre en œuvre lorsque l'on dispose d'une liste exhaustive de la population.
- **Inconvénient** : Risque de biais majeur si la liste de départ comporte une périodicité cachée (un motif qui se répète aux mêmes intervalles).

L'échantillonnage en grappes (Cluster sampling)

- **Le principe** : Diviser la population en sous-groupes naturels (les grappes), puis tirer au sort quelques grappes entières et interroger *tous* leurs membres.

L'échantillonnage en grappes (Cluster sampling)

- **Le principe** : Diviser la population en sous-groupes naturels (les grappes), puis tirer au sort quelques grappes entières et interroger *tous* leurs membres.
- **Exemple** : Au lieu de tirer des lycéens au hasard dans toute la France, on tire au sort 10 lycées, puis on interroge tous les élèves de ces 10 établissements.


L'échantillonnage en grappes (Cluster sampling)

- **Le principe** : Diviser la population en sous-groupes naturels (les grappes), puis tirer au sort quelques grappes entières et interroger *tous* leurs membres.
- **Exemple** : Au lieu de tirer des lycéens au hasard dans toute la France, on tire au sort 10 lycées, puis on interroge tous les élèves de ces 10 établissements.
- **Avantage** : Gain de temps et d'argent considérable sur le terrain.

L'échantillonnage en grappes (Cluster sampling)

- **Le principe** : Diviser la population en sous-groupes naturels (les grappes), puis tirer au sort quelques grappes entières et interroger *tous* leurs membres.
- **Exemple** : Au lieu de tirer des lycéens au hasard dans toute la France, on tire au sort 10 lycées, puis on interroge tous les élèves de ces 10 établissements.
- **Avantage** : Gain de temps et d'argent considérable sur le terrain.
- **Inconvénient** : Moins précis, car les individus d'une même grappe ont tendance à se ressembler socialement ou géographiquement (effet de grappe).

Récapitulatif des types d'échantillonnages



- 1 Avant propos
- 2 Les méthodes d'échantillonnage
- 3 Comment construire un questionnaire ?**
- 4 Comment exploiter les traces ?
- 5 Le recodage des variables

L'enjeu derrière la construction du questionnaire

"Envoyé spécial" : comment la formulation des questions influence les sondages

Publié le 13/04/2017 21:33

⌚ Temps de lecture : 2min - vidéo : 4min




Figure: [Lien](#)

SciencesPo

L'enjeu derrière la construction du questionnaire

- Au-delà donc de l'échantillon choisi, la formulation de la question est donc un élément important dans la conception du questionnaire.

L'enjeu derrière la construction du questionnaire

- Au-delà donc de l'échantillon choisi, la formulation de la question est donc un élément important dans la conception du questionnaire.
- En général, quand le biais provient de l'échantillonnage, il est considéré comme un **biais d'échantillonnage**. Il est légèrement différent du **biais de sélection**.

L'enjeu derrière la construction du questionnaire

- Au-delà donc de l'échantillon choisi, la formulation de la question est donc un élément important dans la conception du questionnaire.
- En général, quand le biais provient de l'échantillonnage, il est considéré comme un **biais d'échantillonnage**. Il est légèrement différent du **biais de sélection**.
- Dans la construction du questionnaire, il existe plusieurs biais possibles.

Biais d'échantillonnage vs Biais de sélection

- **Le biais d'échantillonnage** : Il est lié à la *méthode de tirage*.
L'échantillon final ne représente pas fidèlement la population cible.
 - *Exemple* : Interroger les passants dans la rue à 14h pour une étude sur le travail (exclut les employés de bureau).

Biais d'échantillonnage vs Biais de sélection

- **Le biais d'échantillonnage** : Il est lié à la *méthode de tirage*.
L'échantillon final ne représente pas fidèlement la population cible.
 - *Exemple* : Interroger les passants dans la rue à 14h pour une étude sur le travail (exclut les employés de bureau).
- **Le biais de sélection** : Il est lié au *processus de participation* et au comportement des répondants.
 - **L'auto-sélection** : Seules les personnes très motivées ou très engagées prennent le temps de répondre.
 - **Le biais de survie** : On n'observe que ceux qui sont restés jusqu'au bout du processus (ex: analyser la réussite scolaire uniquement à partir des diplômés).

Quelques exemples de questions biaisées

- "Où comptez-vous partir en vacances cet été ?"

Quelques exemples de questions biaisées

- "Où comptez-vous partir en vacances cet été ?"
 - **Question-piège (présupposition)** : Exclut d'emblée les personnes qui ne partent pas en vacances. Met le répondant mal à l'aise.

Quelques exemples de questions biaisées

- "Où comptez-vous partir en vacances cet été ?"
 - **Question-piège (présupposition)** : Exclut d'emblée les personnes qui ne partent pas en vacances. Met le répondant mal à l'aise.
- "Triez-vous toujours rigoureusement vos déchets pour protéger l'environnement ?"

Quelques exemples de questions biaisées

- "Où comptez-vous partir en vacances cet été ?"
 - **Question-piège (présupposition)** : Exclut d'emblée les personnes qui ne partent pas en vacances. Met le répondant mal à l'aise.
- "Triez-vous toujours rigoureusement vos déchets pour protéger l'environnement ?"
 - **Biais de désirabilité sociale** : Le répondant va avoir tendance à surestimer ses bonnes actions pour donner une image positive de lui-même.

Quelques exemples de questions biaisées

- "Où comptez-vous partir en vacances cet été ?"
 - **Question-piège (présupposition)** : Exclut d'emblée les personnes qui ne partent pas en vacances. Met le répondant mal à l'aise.
- "Triez-vous toujours rigoureusement vos déchets pour protéger l'environnement ?"
 - **Biais de désirabilité sociale** : Le répondant va avoir tendance à surestimer ses bonnes actions pour donner une image positive de lui-même.
- "Êtes-vous favorable à la nécessaire réforme de l'État pour réduire les déficits ?"

Quelques exemples de questions biaisées

- "Où comptez-vous partir en vacances cet été ?"
 - **Question-piège (présupposition)** : Exclut d'emblée les personnes qui ne partent pas en vacances. Met le répondant mal à l'aise.
- "Triez-vous toujours rigoureusement vos déchets pour protéger l'environnement ?"
 - **Biais de désirabilité sociale** : Le répondant va avoir tendance à surestimer ses bonnes actions pour donner une image positive de lui-même.
- "Êtes-vous favorable à la nécessaire réforme de l'État pour réduire les déficits ?"
 - **Biais de cadrage (Question orientée)** : L'utilisation de termes chargés ("nécessaire", "réduire les déficits") oriente fortement vers une réponse positive.

Quelques exemples de questions biaisées

- Il existe plusieurs autres types de biais possibles liés à :
 - La longueur du questionnaire
 - L'ordre des questions
 - Formulation des questions (ambiguïté, niveau de langue, etc.)

Attention aux contraintes légales

- Le règlement général de la protection des données (RGPD) protège les données personnelles et les données sensibles.

Attention aux contraintes légales

- Le règlement général de la protection des données (RGPD) protège les données personnelles et les données sensibles.
- **Les données personnelles :**
 - Toute information permettant d'identifier une personne (Nom, prénom, adresse, téléphone, email, numéro de carte d'identité, IP, localisation)
 - Peut être collectée et traitée sous certaines conditions.

Attention aux contraintes légales

- Le règlement général de la protection des données (RGPD) protège les données personnelles et les données sensibles.
- **Les données personnelles :**
 - Toute information permettant d'identifier une personne (Nom, prénom, adresse, téléphone, email, numéro de carte d'identité, IP, localisation)
 - Peut être collectée et traitée sous certaines conditions.
- **Les données sensibles :**
 - Catégorie spéciale de données présentant un risque accru pour les droits et libertés des individus (Origine raciale ou ethnique, opinions politiques, croyances religieuses, données de santé, données génétiques et biométriques, orientation sexuelle, etc.)
 - Interdiction de collecte et de traitement, sauf exceptions strictes.
 - Nécessite un consentement explicite ou une exception légale (ex. médecine, justice, travail)
 - Sécurité renforcée (pseudonymisation, contrôle d'accès strict, encadrement juridique spécifique).

- 1 Avant propos
- 2 Les méthodes d'échantillonnage
- 3 Comment construire un questionnaire ?
- 4 Comment exploiter les traces ?**
- 5 Le recodage des variables

A quoi ressemblent des traces ?

†

J. ^c John Williams	J. ^c Thomas Walter
J. ^c Rob. ^t John	J. ^c Amb. ^d Spencer
J. ^c Edwyn Sondys	M. ^c Prowse
J. ^c John Trevor	

To Consider of the In-
corporation of the Spanish
Company Tuesday
4 febr.^y Temple Hall
The Burgeses of Lyn

To Morrow in the Temple Hall
This Last night the upper House of
Parliament was searched by J.^c Thomas
Knewst, and one Johnson servant to M.^c —
Thomas Pearey was there apprehended, who
had plaid Thirty Six Barrells of Powder
in the Vault under the House with a pur-
pose to blow King and the whole Company
when they should there assemble
Afterwards divers other Gentlemen
were discovered to be of the Plott.

A quoi ressemblent les traces ?



A quoi ressemblent les traces ?

- Quel lien donc entre les deux graphiques?

A quoi ressemblent les traces ?

- Quel lien donc entre les deux graphiques?
 - Les deux génèrent des informations susceptible à être transformées en bases de données

A quoi ressemblent les traces ?

- Quel lien donc entre les deux graphiques?
 - Les deux génèrent des informations susceptible à être transformées en bases de données
 - Ce sont donc des sources de données issues de traces

A quoi ressemblent les traces ?

- Quel lien donc entre les deux graphiques?
 - Les deux génèrent des informations susceptible à être transformées en bases de données
 - Ce sont donc des sources de données issues de traces
- Mais comment donc exploiter ces sources d'informations pour en faire une base de données ?

- Contrairement aux questionnaires, les traces (archives, posts sur les réseaux, registres) ne sont pas structurées pour l'analyse statistique initiale.
- Il faut donc opérer des choix subjectifs pour les transformer en variables (ex: transformer un texte libre en une catégorie).
- Exemple type : Le registre des enfants arrêtés pendant la Commune de Paris (1871) établi par Jean-Claude Farcy. La colonne "Profession" contient des centaines de descriptions libres, souvent avec des fautes d'orthographe ou des synonymes...

De la trace à la donnée

N° d'ordre	Noms et prénoms	Age	âge (nombre)	Lieu et date	Lieu de nais.	Date de nais.	Profession de l'enfant	Domicile
84	Gronlier Paul	14 ans 1/2		14.5 Paris, le 24/11/	Paris	24/11/1856	Apprenti boucher	Rue Princesse, 12 (Odéon)
102	Lecomte Ernest	17 ans		17 Cambrai (Nord)	Cambrai (Nord)		Boucher	Rue de Flandre, 76
122	Parmentier Em	15 ans		15 Reims (Marne)	Reims (Marne)	25/4/1856	Garçon boucher	Rue de l'Argent, 24 (Villette)
194	Bourdon Jules	13 ans 1/2		13.5 Pantin (Seine)	Pantin (Seine)	25/12/1857	Garçon boucher	Rue Marcadet, 11
196	David Jules	16 ans		16 La Ferté-Berna	La Ferté-Berna	4/5/1855	Garçon boucher	Rue Vitruve, 17
231	Girault Jules	15 ans 1/2		15.5 Paris, le 20/12/	Paris	20/12/1855	Garçon boucher	Rue de l'Ourcq, 67
252	Guffroy Charles	14 ans 1/2		14.5 Douai (Nord)	Douai (Nord)	5/1/1857	Apprenti boucher	Rue Ménadier, 5
264	Débonnaire Ga	16 ans 1/2		16.5 Ozoer-le-Voul	Ozoer-le-Voul	25/3/1855	Garçon boucher	Rue Garibaldi, 14 ; rue du Cherche Mid
334	Barthelet Eugè	15 ans		15 Paris, le 9/7/18	Paris	9/7/1856	Boucher	Rue de la Procession, 140
348	Didiot Léonard	14 ans 1/2		14.5 Heippes (Meus	Heippes (Meus)	1857	Boucher	Avenue de Saint-Ouen, passage Saint-I
353	Fermond Adrie	14 ans 1/2		14.5 Lyon (Rhône)	Lyon (Rhône)	7/12/1856	Garçon boucher	Quai de l'Hôtel de Ville, 70 ; rue Saint-M
380	Turpin Emilie	16 ans		16 Boursonne (Oit	Boursonne (Oit)	1856	Garçon boucher	Auteuil, rue Gros, 2
398	Mansais Alfred	14 ans		14 Paris, le 1/7/18	Paris	1/7/1857	Boucher	Rue d'Aboukir, 132
417	Dietz Paul	16 ans		16 Paris, le 31/5/1	Paris	31/5/1855	Garçon boucher	Avenue du Roi de Rome, 98 ; rue Boiss
453	Callet Alphonse	17 ans		17 Paris, le 15/1/1	Paris	15/1/1855	Apprenti boucher	Rue de Sèvres, 114
636	Ritter Emilie	16 ans		16 Paris	Paris		Garçon boucher	Passage Saint-Nicolas Marie, à Auberv

Figure: Exemple de base de données issue de traces historiques non structurées

- 1 Avant propos
- 2 Les méthodes d'échantillonnage
- 3 Comment construire un questionnaire ?
- 4 Comment exploiter les traces ?
- 5 Le recodage des variables

Rappel sur le recodage des variables

- Face à cette diversité de réponses (dans un questionnaire ouvert ou une trace), il est indispensable de recoder.
- Cette étape (parfois appelée à tort "nettoyage") nécessite de faire des choix forts : qui décide que "paysan", "journalier" et "agriculteur" vont dans la même case ?
- L'objectif du recodage est de créer de **nouvelles variables catégorielles ou quantitatives** adaptées à nos besoins analytiques, à partir des variables brutes.

- **La perte d'information** : Passer d'une variable continue (âge exact) à une variable catégorielle (tranche d'âge) simplifie l'analyse, mais détruit la finesse de la donnée initiale.

Les enjeux et défis méthodologiques du recodage

- **La perte d'information** : Passer d'une variable continue (âge exact) à une variable catégorielle (tranche d'âge) simplifie l'analyse, mais détruit la finesse de la donnée initiale.
- **La subjectivité et l'arbitraire** : C'est le chercheur qui fixe les frontières.
 - *Exemple* : Définir un "Jeune" comme "moins de 25 ans" ou "moins de 30 ans" modifiera directement les conclusions statistiques.

Les enjeux et défis méthodologiques du recodage

- **La perte d'information** : Passer d'une variable continue (âge exact) à une variable catégorielle (tranche d'âge) simplifie l'analyse, mais détruit la finesse de la donnée initiale.
- **La subjectivité et l'arbitraire** : C'est le chercheur qui fixe les frontières.
 - *Exemple* : Définir un "Jeune" comme "moins de 25 ans" ou "moins de 30 ans" modifiera directement les conclusions statistiques.
- **Le traitement épineux des non-réponses** : Que faire des cases vides, des "Ne sait pas" ou des réponses aberrantes ?
 - Les exclure réduit la taille de l'échantillon. Créer une catégorie "Non-réponse" modifie la répartition des pourcentages globaux.

Exemples de recodage

- On peut recoder une variable catégorielle en une nouvelle variable catégorielle en la **re-catégorisant** (ex: regrouper des dizaines de métiers en 5 PCS).

Exemples de recodage

- On peut recoder une variable catégorielle en une nouvelle variable catégorielle en la **re-catégorisant** (ex: regrouper des dizaines de métiers en 5 PCS).
- On peut recoder des variables quantitatives en nouvelles variables quantitatives grâce aux opérations mathématiques (ex: Date de jugement - Date d'arrestation = Durée de détention).

Exemples de recodage

- On peut recoder une variable catégorielle en une nouvelle variable catégorielle en la **re-catégorisant** (ex: regrouper des dizaines de métiers en 5 PCS).
- On peut recoder des variables quantitatives en nouvelles variables quantitatives grâce aux opérations mathématiques (ex: Date de jugement - Date d'arrestation = Durée de détention).
- On peut recoder des variables quantitatives en nouvelles variables catégorielles **en regroupant les observations dans des classes** (ex: tranches d'âges).